HỌC VIỆN NGÂN HÀNG
BANKING ACADEMY OF VIETNAM

Mô hình học máy



OUTLINE

Part 1 **Part 1**

GIỚI THIỆU VỀ MACHINE LEARNING

Part 2 **Part 2**

ỨNG DỤNG MACHINE LEARNING
TRONG PHÂN TÍCH DỮ LIỆU

Part 3 **Part 3**

DỰ BÁO MÔ HÌNH VỚI CHUỖI THỜI GIAN



Giới thiệu về machine learning

Hiểu khái niệm cơ bản về machine learning và cách thực hiện



Python

Hiểu python và ứng dụng của Python



Xử lý dữ liệu trên Python

Biết cách xử lý dữ liệu trên Python

Học máy đang thay đổi thế giới như thế nào?

- 📱 Dự đoán hành vi người dùng trong thương mại điện tử (Shopee, Tiki, Amazon)
- 🚗 Xe tự lái (Autonomous Driving – Tesla)
- 🧠 Chẩn đoán bệnh qua hình ảnh y khoa
- 🎬 Hệ thống gợi ý phim (Netflix, YouTube)
- 💬 Chatbot AI, dịch tự động, nhận diện giọng nói
- 📷 Nhận diện khuôn mặt và bảo mật sinh trắc học

🧠 1. Giai đoạn khởi đầu (trước 1950)

•**1943** – McCulloch & Pitts: Mô hình nơ-ron nhân tạo đầu tiên (Artificial Neuron).
•**1950** – Alan Turing giới thiệu **Turing Test**, kiểm tra xem máy có thể "nghĩ" như con người không.

🤖 2. Giai đoạn sơ khai của AI (1956–1970)

•**1956** – Hội nghị Dartmouth: John McCarthy đặt ra thuật ngữ **Artificial Intelligence**.
•**1959** – Arthur Samuel tạo ra chương trình chơi cờ dama biết tự học (**machine learning đầu tiên**).
•AI ban đầu tập trung vào **logic, tìm kiếm, trò chơi, và chứng minh toán học**.

3. Mùa đông AI lần 1 (1970–1980)

•Lạc quan ban đầu quá cao, nhưng máy tính hạn chế.
•Không có đủ dữ liệu, phần cứng yếu.
•Tài trợ nghiên cứu AI bị cắt giảm, niềm tin suy giảm.

4. AI dựa luật và chuyên gia (1980–1987)

•Sự nổi lên của **Expert Systems**: chương trình dựa trên luật IF-THEN mô phỏng chuyên gia con người.

5. Mùa đông AI lần 2 (1987–1993)
•Expert Systems thất bại trong thực tế do khó mở rộng và duy trì.
•Thiếu hiệu quả và linh hoạt.

6. Trỗi dậy của học máy (1990–2000)
•Sự thay đổi từ AI biểu tượng sang **machine learning**: học từ dữ liệu thay vì lập trình luật rõ ràng.
•Sử dụng các thuật toán thống kê: **Decision Tree, Naive Bayes, SVM, KNN**.
✅ Cột mốc:
•1997 – Máy tính IBM Deep Blue thắng nhà vô địch cờ vua Garry Kasparov.

🌐 **7. Học sâu và Big Data (2006–nay)**
•**2006** – Geoffrey Hinton giới thiệu lại **Deep Learning** (Học sâu) – mạng nơ-ron nhiều tầng.
•**2012** – Mạng deep learning (AlexNet) chiến thắng cuộc thi ImageNet, đưa DL trở thành trung tâm AI.
✅ Công nghệ hỗ trợ:
•GPU mạnh mẽ, dữ liệu lớn (Big Data), mã nguồn mở (TensorFlow, PyTorch...).
✅ Các ứng dụng bùng nổ:
•Nhận diện hình ảnh, xử lý ngôn ngữ tự nhiên (GPT, BERT...), xe tự lái, chatbot, y tế, tài chính...

🌎 **8. AI hiện đại (2020–nay)**
•**AI tạo sinh (Generative AI)**: như ChatGPT, Midjourney, Sora…
•**Học tăng cường (Reinforcement Learning)**: giúp máy học qua hành động – nổi bật trong game và robot.
•**AutoML, AI Ethics, Explainable AI**: tập trung vào dễ hiểu, an toàn và có trách nhiệm.

1. Khái niệm về học máy

VÌ SAO PHẢI PHÂN LOẠI DỮ LIỆU?

Dữ liệu là những ghi nhận về thế giới thực đã được số hoá: con số, chữ viết, hình ảnh, âm thanh, tín hiệu cảm biến.

Cách dữ liệu được tổ chức quyết định ba việc:

lưu ở đâu — cơ sở dữ liệu quan hệ, kho dữ liệu, hồ dữ liệu (data lake), cơ sở dữ liệu vector;
xử lý bằng gì — SQL, bảng tính, thư viện xử lý ảnh, mô hình ngôn ngữ;
mô hình nào dùng được — hồi quy và cây quyết định cần bảng; mạng nơ-ron sâu mới xử lý trực tiếp được ảnh và văn bản.

Vì vậy câu hỏi đầu tiên của mọi dự án phân tích không phải là "dùng mô hình gì" mà là "dữ liệu của tôi thuộc loại nào".

DỮ LIỆU CÓ CẤU TRÚC

Dữ liệu có cấu trúc (structured data) là dữ liệu được tổ chức theo mô hình định sẵn: mỗi **hàng** là một quan sát, mỗi **cột** là một biến có kiểu dữ liệu xác định.

Đặc điểm. Có lược đồ (schema) rõ ràng; kiểu dữ liệu cố định (số, ngày, chuỗi, nhị phân); truy vấn được bằng SQL; dễ tổng hợp, lọc, tính trung bình.

Nơi lưu trữ. Cơ sở dữ liệu quan hệ (MySQL, PostgreSQL, Oracle), kho dữ liệu (data warehouse), bảng tính, tệp CSV.

Ví dụ. Bảng giao dịch ngân hàng; hồ sơ nhân sự; danh mục sản phẩm và giá; số liệu điều tra mức sống hộ gia đình; báo cáo tài chính theo mẫu.

Ưu điểm. Dễ kiểm soát chất lượng, dễ chia sẻ, dùng được ngay với hầu hết mô hình thống kê cổ điển. **Hạn chế.** Chỉ mô tả được những gì đã được định nghĩa trước; mọi sắc thái nằm ngoài lược đồ đều bị mất.

VÍ DỤ MỘT BẢNG DỮ LIỆU CÓ CẤU TRÚC

Mã KH	Tuổi	Thu nhập (tr/tháng)	Số năm làm việc	Dư nợ (tr)	Vỡ nợ
KH001	34	18.5	8	220	0
KH002	27	12.0	3	150	1
KH003	45	31.2	20	480	0
KH004	52	26.8	25	610	0
KH005	23	9.4	1	80	1

Mỗi **hàng** là một quan sát (một khách hàng). Mỗi **cột** là một biến, còn gọi là một **đặc trưng** (feature). Cột cuối "Vỡ nợ" là **nhãn** (label) — thứ ta muốn dự đoán.

Với cấu trúc này, câu hỏi "tỷ lệ vỡ nợ của nhóm thu nhập dưới 15 triệu là bao nhiêu?" chỉ mất một dòng lệnh SQL.

DỮ LIỆU PHI CẤU TRÚC

Dữ liệu phi cấu trúc (unstructured data) không tuân theo một lược đồ định sẵn: không có hàng, không có cột, không có kiểu dữ liệu cố định.

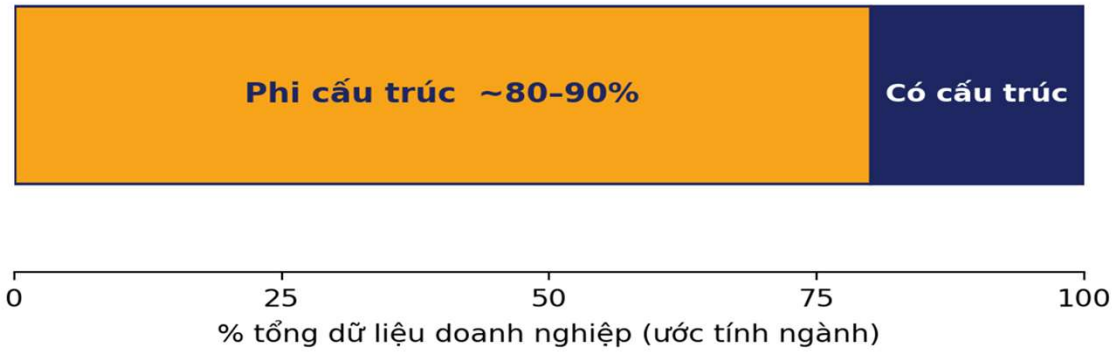
Ví dụ. Văn bản tự do (email, hợp đồng, tin nhắn chăm sóc khách hàng, bình luận mạng xã hội); hình ảnh (ảnh chụp căn cước, ảnh vệ tinh, ảnh y tế); âm thanh (ghi âm tổng đài); video; tệp PDF quét.

Vì sao khó. Không truy vấn được bằng SQL; ý nghĩa nằm trong ngữ cảnh chứ không nằm trong một ô; cùng một nội dung có vô số cách diễn đạt; khối lượng rất lớn.

Nhưng giá trị rất cao. Lý do thật sự khiến khách hàng rời bỏ ngân hàng thường nằm trong email khiếu nại, chứ không nằm trong bảng giao dịch.

Cách xử lý hiện nay. Dùng mô hình học sâu để chuyển dữ liệu phi cấu trúc thành **vector số** (embedding) — sau bước đó, mọi công cụ dành cho dữ liệu có cấu trúc lại dùng được.

PHẦN LỚN DỮ LIỆU LÀ PHI CẤU TRÚC



Các ước tính của giới công nghệ (IDC, Gartner và các nhà cung cấp lưu trữ) đều cho con số tương tự: khoảng **80–90%** dữ liệu mà một tổ chức nắm giữ là **phi cấu trúc**, và tỷ trọng này đang tăng.

Cần đọc con số này một cách thận trọng: đây là **ước tính của ngành**, không phải một phép đo chính xác, và cách phân loại khác nhau giữa các báo cáo.

Hàm ý thực tiễn: nếu chỉ biết làm việc với bảng biểu, ta đang bỏ qua phần lớn thông tin mà tổ chức của mình đang có.

DỮ LIỆU BÁN CẤU TRÚC

Dữ liệu bán cấu trúc (semi-structured data) không có lược đồ bảng cứng nhắc, nhưng mang **thẻ đánh dấu** hoặc **khoá – giá trị** cho biết đâu là thông tin gì.

Ví dụ. Tệp JSON và XML; nhật ký hệ thống (log); email (có trường Người gửi, Chủ đề, Ngày — nhưng phần thân là văn bản tự do); dữ liệu từ giao diện lập trình ứng dụng (API); dữ liệu cảm biến IoT.

Đây là dạng phổ biến nhất khi lấy dữ liệu từ Internet hoặc từ hệ thống của bên thứ ba. Bước đầu tiên của hầu hết dự án là **làm phẳng** dữ liệu bán cấu trúc thành bảng.

Ranh giới giữa ba loại không tuyệt đối. Một tệp PDF có thể vừa chứa bảng số liệu (có cấu trúc) vừa chứa đoạn thuyết minh (phi cấu trúc).

SO SÁNH BA LOẠI DỮ LIỆU

Tiêu chí	Có cấu trúc	Bán cấu trúc	Phi cấu trúc
Tổ chức	Bảng, hàng và cột	Thẻ, khoá – giá trị	Không có lược đồ
Ví dụ	CSV, bảng SQL	JSON, XML, log	Ảnh, video, văn bản
Truy vấn	SQL	Cần phân tích cú pháp	Cần mô hình học sâu
Nơi lưu	Kho dữ liệu	Hồ dữ liệu, NoSQL	Hồ dữ liệu, CSDL vector
Tỷ trọng	Nhỏ	Trung bình	Rất lớn
Độ khó	Thấp	Trung bình	Cao

Càng sang phải, dữ liệu càng **giàu thông tin** nhưng càng **khó khai thác**. Học máy hiện đại chính là công cụ giúp thu hẹp khoảng cách đó.

TỪ DỮ LIỆU THÔ ĐẾN ĐẶC TRƯNG

Mô hình học máy không "đọc" dữ liệu thô. Chúng chỉ làm việc với các con số. Bước biến dữ liệu thô thành bảng số gọi là kỹ thuật đặc trưng (feature engineering).

Biến phân loại (giới tính, tỉnh thành) → mã hoá thành các biến 0/1;
Ngày tháng → tách thành thứ trong tuần, tháng, số ngày kể từ một mốc;
Văn bản → đếm từ, hoặc chuyển thành vector nhúng (embedding);
Ảnh → ma trận điểm ảnh, hoặc vector đặc trưng do mạng nơ-ron sinh ra.

Trong thực tế, chất lượng đặc trưng quan trọng hơn độ phức tạp của mô hình. Một mô hình đơn giản với đặc trưng tốt thường thắng một mô hình phức tạp với đặc trưng kém.

CHẤT LƯỢNG DỮ LIỆU

- **Thiếu dữ liệu. Ô trống có thể ngẫu nhiên, nhưng thường không: người thu nhập cao hay bỏ trống câu hỏi về thu nhập. Xoá bừa các hàng thiếu sẽ làm lệch mẫu.**
- **Nhiễu và sai sót. Nhập sai đơn vị, sai dấu thập phân, giá trị bất thường (outlier). Luôn vẽ phân phối của từng biến trước khi làm bất cứ điều gì khác.**
- **Thiên lệch mẫu. Dữ liệu chỉ từ khách hàng đã được duyệt vay không nói gì về những người bị từ chối — mô hình học từ đó sẽ tái tạo lại đúng định kiến cũ.**

Nguyên tắc bất di bất dịch: rác vào thì rác ra. Không mô hình nào cứu được dữ liệu tồi.

THẢO LUẬN

Một ngân hàng muốn dự đoán khách hàng nào sắp đóng tài khoản.

1. Liệt kê 5 nguồn dữ liệu ngân hàng có thể dùng. Xếp mỗi nguồn vào một trong ba loại: có cấu trúc, bán cấu trúc, phi cấu trúc.

2. Từ lịch sử giao dịch, hãy đề xuất 4 đặc trưng có thể tạo ra.

3. Chỉ ra một biến mà nếu đưa vào mô hình sẽ gây **rò rỉ dữ liệu**, và giải thích vì sao.

HỌC MÁY LÀ GÌ?

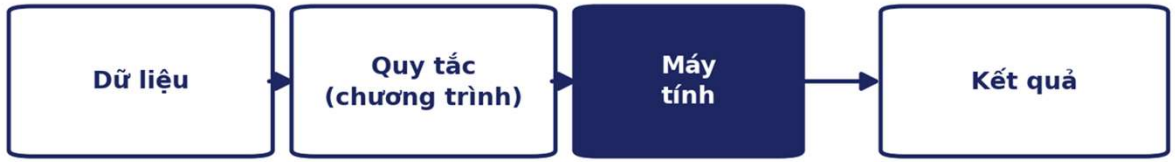
Arthur Samuel (1959) — lĩnh vực nghiên cứu trao cho máy tính khả năng học mà **không cần được lập trình một cách tường minh**.

Tom Mitchell (1997) — một chương trình máy tính được nói là **học** từ kinh nghiệm **E** đối với một lớp nhiệm vụ **T** và thước đo hiệu năng **P**, nếu hiệu năng của nó tại các nhiệm vụ trong T, đo bằng P, **được cải thiện nhờ kinh nghiệm E**.

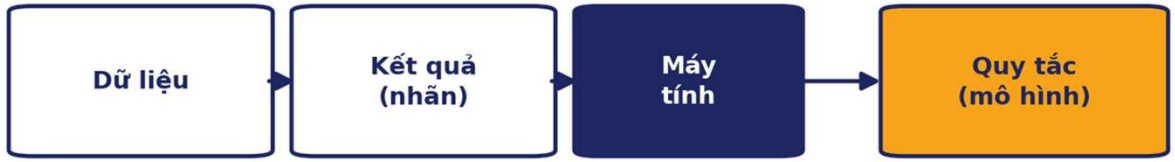
Ví dụ áp dụng định nghĩa của Mitchell cho bài toán lọc thư rác:
T = phân loại thư đến là rác hay không rác. E = tập thư đã được người dùng đánh dấu.
P = tỷ lệ phân loại đúng trên những thư chưa từng thấy.

LẬP TRÌNH TRUYỀN THỐNG VÀ HỌC MÁY

Lập trình truyền thống

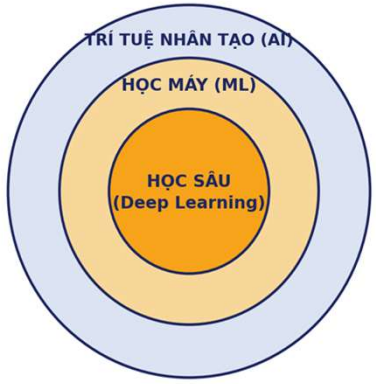


Học máy



Lập trình truyền thống: con người viết **quy tắc**, máy áp dụng lên dữ liệu để cho ra kết quả. Học máy đảo ngược sơ đồ: ta đưa vào **dữ liệu cùng kết quả đã biết**, máy tìm ra quy tắc.

AI, HỌC MÁY VÀ HỌC SÂU



Mô hình nền tảng và LLM là một nhánh của học sâu

Trí tuệ nhân tạo (AI) — mọi kỹ thuật giúp máy thực hiện những việc vốn cần trí tuệ con người, kể cả hệ chuyên gia dựa trên luật.

Học máy (ML) — nhánh của AI trong đó máy học từ dữ liệu thay vì được lập trình luật.

Học sâu (Deep Learning) — nhánh của học máy dùng mạng nơ-ron nhiều lớp; đây là công nghệ đứng sau nhận dạng ảnh, dịch máy và các mô hình ngôn ngữ lớn.

Ba khái niệm này **lồng vào nhau**, không phải ba thứ song song. Nói "dự án AI" khi thực chất đang làm hồi quy logistic là cách dùng từ gây hiểu nhầm.

BA THÀNH PHẦN CỦA MỘT MÔ HÌNH HỌC MÁY

1. DỮ LIỆU
tập các quan sát, mỗi quan sát gồm các đặc trưng, và (nếu có) một nhãn

2. MÔ HÌNH
một họ hàm số có tham số, mô tả cách đặc trưng liên hệ với nhãn

3. HÀM MẤT MÁT
thước đo mức độ sai của mô hình, dùng để chọn ra bộ tham số tốt nhất

Huấn luyện (training) chính là quá trình đi tìm bộ tham số làm cho hàm mất mát nhỏ nhất trên dữ liệu huấn luyện.

Ba thành phần này có mặt trong **mọi** thuật toán học máy, từ hồi quy tuyến tính cho tới mô hình ngôn ngữ lớn. Cái thay đổi chỉ là họ hàm và cách tối ưu.

Điểm nối với thống kê: ước lượng bình phương nhỏ nhất (OLS) chính là "mô hình tuyến tính + hàm mất mát bình phương sai số".

2. Quy trình mô hình học máy

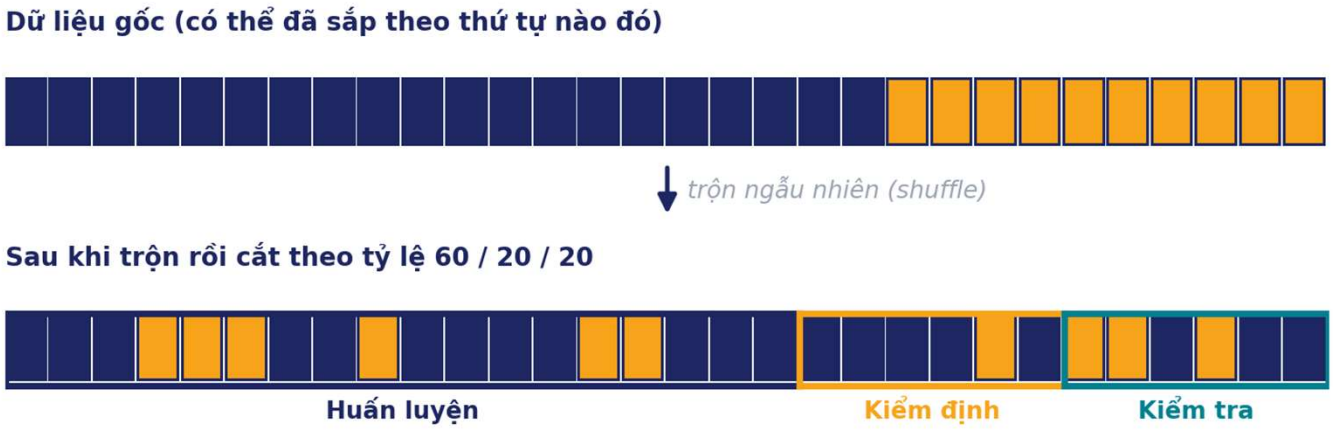
Bước	Nội dung	Sai lầm thường gặp
1	Xác định bài toán và thước đo thành công	Bắt đầu từ mô hình thay vì từ câu hỏi
2	Thu thập và mô tả dữ liệu	Không kiểm tra nguồn gốc và tính đại diện
3	Làm sạch, xử lý thiếu và ngoại lai	Xoá hết hàng thiếu, làm lệch mẫu
4	Tạo đặc trưng	Vô tình đưa vào biến gây rò rỉ dữ liệu
5	Chia tập huấn luyện / kiểm định / kiểm tra	Chia sau khi đã xử lý toàn bộ dữ liệu
6	Huấn luyện và tinh chỉnh siêu tham số	Tinh chỉnh trên tập kiểm tra
7	Đánh giá trên tập kiểm tra	Chọn chỉ số không phù hợp bài toán
8	Triển khai và giám sát	Không theo dõi khi phân phối dữ liệu đổi

CHIA DỮ LIỆU THÀNH BA TẬP



Tập huấn luyện (training set) dùng để ước lượng tham số của mô hình.
Tập kiểm định (validation set) dùng để chọn siêu tham số — độ sâu của cây, số cụm, mức phạt — và để so sánh các mô hình với nhau.
Tập kiểm tra (test set) chỉ được dùng **đúng một lần**, ở cuối cùng, để báo cáo hiệu năng. Nếu dùng nó để chọn mô hình thì con số báo cáo sẽ lạc quan hơn thực tế.
Vì sao không đánh giá ngay trên tập huấn luyện? Vì mô hình đã "nhìn thấy" những dữ liệu đó — kết quả sẽ tốt một cách giả tạo. Ta cần biết mô hình chạy ra sao trên dữ liệu **chưa từng thấy**.
Tỷ lệ thường dùng: 60/20/20 hoặc 70/15/15. Không có con số bắt buộc — dữ liệu càng nhiều thì tỷ lệ dành cho kiểm định và kiểm tra càng có thể nhỏ.

CÁCH 1: CHIA NGẪU NHIÊN (RANDOM SPLIT)



Quy trình. (1) Trộn ngẫu nhiên toàn bộ quan sát; (2) cắt theo tỷ lệ đã chọn; (3) cố định **hạt giống ngẫu nhiên (random seed)** để kết quả lặp lại được.

Trộn trước khi cắt là bắt buộc: dữ liệu thường được sắp xếp theo mã khách hàng, theo chi nhánh hoặc theo nhãn — cắt thẳng sẽ tạo ra hai tập hoàn toàn khác nhau về bản chất.

ƯU VÀ NHƯỢC CỦA CHIA NGẪU NHIÊN

ƯU ĐIỂM

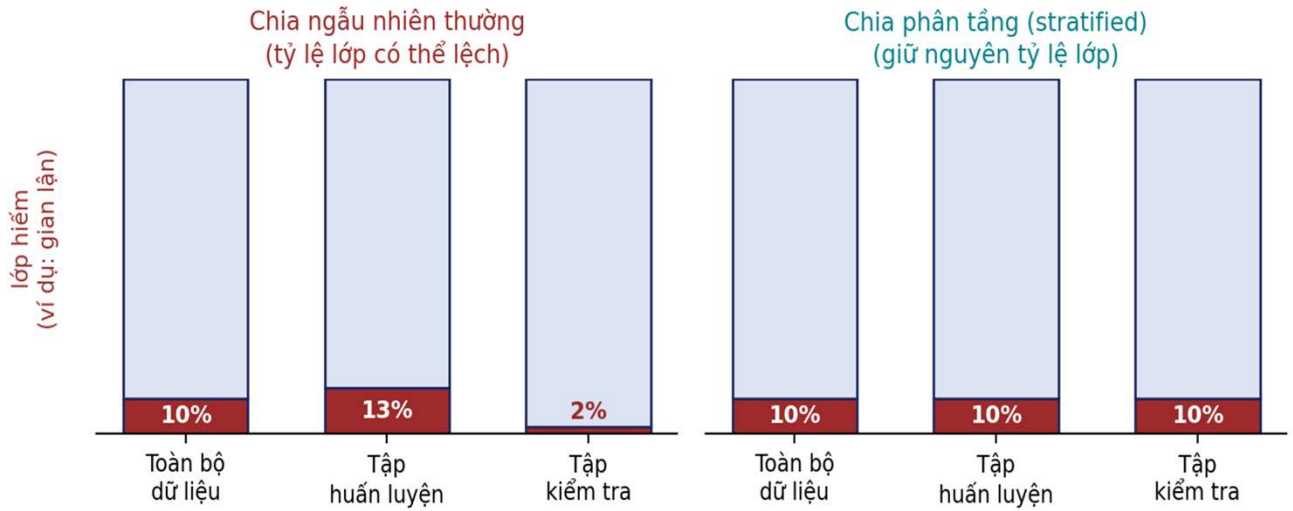
- rất đơn giản, chỉ một dòng lệnh;
- nhanh — chỉ huấn luyện mô hình **một lần**;
- phù hợp khi dữ liệu **rất lớn**, vì khi đó mỗi tập đều đủ đại diện;
- dễ giải thích cho người ngoài chuyên môn.

NHƯỢC ĐIỂM

- kết quả **phụ thuộc vào một lần bốc thăm may rủi**: đổi seed có thể đổi kết luận;
- khi dữ liệu ít, tập kiểm tra quá nhỏ nên ước lượng hiệu năng rất nhiễu;
- "lãng phí" dữ liệu: 20–40% số quan sát không được dùng để huấn luyện;
- có thể làm lệch tỷ lệ lớp hoặc tách nhầm các quan sát có liên hệ với nhau.

Chính bốn nhược điểm này dẫn tới **kiểm định chéo (cross-validation)**.

KHI CHIA NGẪU NHIÊN LÀ SAI: PHÂN TẦNG



Khi một lớp rất hiếm — gian lận, vỡ nợ, bệnh hiếm — chia ngẫu nhiên thuần tuý có thể khiến tỷ lệ lớp trong các tập lệch hẳn nhau, thậm chí tập kiểm tra gần như không còn quan sát nào thuộc lớp hiếm.

Chia phân tầng (stratified split) bốc thăm **riêng trong từng lớp**, nhờ đó tỷ lệ lớp trong tập huấn luyện và tập kiểm tra bằng đúng tỷ lệ của toàn bộ dữ liệu.

KHI CHIA NGẪU NHIÊN LÀ SAI: NHÓM VÀ THỜI GIAN



Dữ liệu có nhóm. Nếu một khách hàng có nhiều giao dịch, chia ngẫu nhiên sẽ đặt vài giao dịch của cùng người vào cả hai tập — mô hình "nhận ra" người đó và điểm số bị thổi phồng. Cách đúng: **chia theo nhóm** (group split), cả nhóm nằm trọn trong một tập.

Dữ liệu theo thời gian. Không được trộn: dùng dữ liệu tương lai để dự báo quá khứ là vô nghĩa. Cách đúng là **chia theo mốc thời gian**, huấn luyện trên quá khứ và kiểm định trên tương lai, như sơ đồ trên (cửa sổ mở rộng).

CÁCH 2: KIỂM ĐỊNH CHÉO k PHẦN (k-FOLD)

Lần 1	**Kiểm định**	Huấn luyện	Huấn luyện	Huấn luyện	Huấn luyện
Lần 2	Huấn luyện	**Kiểm định**	Huấn luyện	Huấn luyện	Huấn luyện
Lần 3	Huấn luyện	Huấn luyện	**Kiểm định**	Huấn luyện	Huấn luyện
Lần 4	Huấn luyện	Huấn luyện	Huấn luyện	**Kiểm định**	Huấn luyện
Lần 5	Huấn luyện	Huấn luyện	Huấn luyện	Huấn luyện	**Kiểm định**

Hiệu năng cuối cùng = trung bình của 5 lần đánh giá

Mỗi quan sát được dùng để kiểm định đúng một lần, và để huấn luyện k − 1 lần

Chia dữ liệu thành k phần bằng nhau rồi lặp lại việc huấn luyện – đánh giá **k lần**, mỗi lần để một phần khác nhau làm tập kiểm định.

Các loại dữ liệu trong Machine Learning

Dữ liệu là nền tảng của ML, và được phân loại dựa trên cấu trúc và mục đích sử dụng. Các loại dữ liệu chính bao gồm:

a. Dữ liệu có nhãn (Labeled Data)

Định nghĩa: Dữ liệu có nhãn bao gồm cả đầu vào (input) và đầu ra (output) mong muốn, được sử dụng trong học có giám sát.

Cấu trúc:

· Đặc điểm (Features): Các biến đầu vào (ví dụ: tuổi, thu nhập, lịch sử giao dịch).

· Nhãn (Labels): Giá trị đầu ra cần dự đoán (ví dụ: trạng thái khoản vay - approved/rejected).

Ví dụ trong ngân hàng: Dữ liệu khách hàng với các đặc điểm (tuổi, thu nhập, số dư tài khoản) và nhãn (điểm tín dụng: tốt/xấu).

Ứng dụng: Dự đoán rủi ro tín dụng, phân loại khách hàng.

Thách thức: Yêu cầu dữ liệu có nhãn chất lượng cao, tốn thời gian và chi phí để gắn nhãn.

b. Dữ liệu không có nhãn (Unlabeled Data)

Định nghĩa: Dữ liệu không có nhãn chỉ chứa các đặc điểm (features) mà không có đầu ra xác định, dùng trong học không giám sát.

Cấu trúc: Chỉ có các đặc điểm (ví dụ: lịch sử giao dịch, hành vi chi tiêu).

Ví dụ trong ngân hàng: Dữ liệu giao dịch với các cột: transaction_amount, date, location, nhưng không có nhãn xác định giao dịch là bình thường hay gian lận.

Ứng dụng: Phân cụm khách hàng, phát hiện gian lận.

Thách thức: Khó đánh giá kết quả vì không có nhãn để so sánh.

Phân nhóm khách hàng (Customer Segmentation)
Tình huống:
Một công ty thương mại điện tử muốn chia khách hàng thành các nhóm để cá nhân hóa chiến dịch tiếp thị. Dữ liệu có gồm: số lần mua hàng, số tiền đã chi, tần suất truy cập website, thời gian truy cập...
Bài toán:
Hãy sử dụng dữ liệu hành vi khách hàng để phân nhóm các khách hàng thành các cụm có hành vi tương đồng.

🟥 **Loại dữ liệu:** Không có nhãn (unsupervised learning) – không biết trước nhóm nào là "VIP", "thường", "không tiềm năng".

2. Phát hiện gian lận (Anomaly Detection)
Tình huống:
Ngân hàng muốn phát hiện các giao dịch đáng ngờ trong dữ liệu hàng triệu giao dịch tài chính. Dữ liệu chỉ gồm thông tin về số tiền, thời gian, vị trí, tần suất giao dịch,...
Bài toán:
Tìm các giao dịch bất thường mà không có dữ liệu nào được dán nhãn là "gian lận".

3. Phân loại chủ đề tin tức (Topic Modeling)
Tình huống:
Một tòa soạn muốn tổ chức hàng ngàn bài báo cũ thành các chủ đề như chính trị, kinh tế, thể thao, giải trí,... nhưng không có thông tin gán nhãn chủ đề trước đó.
Bài toán:
Phân tích nội dung bài viết để chia thành các nhóm chủ đề chính.

Loại dữ liệu: Không có nhãn – mô hình sẽ tự tìm ra các chủ đề (topics) tiềm ẩn trong dữ liệu văn bản.

4. Nhận diện cụm sản phẩm (Product Clustering)
Tình huống:
Một chuỗi siêu thị muốn nhóm các sản phẩm tương đồng để tối ưu hóa trưng bày trên kệ hoặc gợi ý mua hàng.
Bài toán:
Sử dụng dữ liệu như giá, chủng loại, tần suất mua, trọng lượng... để phân cụm sản phẩm.

Loại dữ liệu: Không có nhãn – không có thông tin sản phẩm thuộc cụm nào từ trước.

k-FOLD: CÁC BƯỚC THỰC HIỆN

Bước 1. Tách riêng **tập kiểm tra** ra trước và khoá lại. Kiểm định chéo được thực hiện trên phần dữ liệu còn lại.
Bước 2. Trộn ngẫu nhiên phần còn lại rồi chia thành **k phần (fold)** bằng nhau, thường k = 5 hoặc k = 10.
Bước 3. Với mỗi i = 1, …, k: huấn luyện mô hình trên k − 1 phần, đánh giá trên phần thứ i, ghi lại chỉ số hiệu năng P_i.
Bước 4. Tính **trung bình** và **độ lệch chuẩn** của k giá trị:

$$\bar{P} = (P_1 + P_2 + \ldots + P_k) / k \qquad \text{và} \qquad s = \text{độ lệch chuẩn của } \{P_i\}$$

Bước 5. Chọn mô hình hoặc siêu tham số có $\bar{P}$ tốt nhất, huấn luyện lại trên **toàn bộ** dữ liệu ngoài tập kiểm tra, rồi đánh giá **một lần duy nhất** trên tập kiểm tra.
Độ lệch chuẩn s cũng quan trọng: nếu s lớn, hiệu năng của mô hình rất nhạy với việc chia dữ liệu — dấu hiệu dữ liệu quá ít hoặc mô hình thiếu ổn định.

CHỌN k VÀ CÁC BIẾN THỂ CỦA k-FOLD

Biến thể	Cách làm	Dùng khi
k-fold thường	k = 5 hoặc k = 10	Trường hợp mặc định
Phân tầng (stratified)	Giữ tỷ lệ lớp trong từng phần	Phân loại mất cân bằng
Leave-one-out (LOOCV)	k = n, mỗi lần bỏ ra đúng một quan sát	Dữ liệu rất ít; tốn kém
Lặp lại (repeated)	Chạy k-fold nhiều lần, seed khác nhau	Muốn ước lượng ổn định hơn
Theo nhóm (group)	Cả nhóm nằm trọn trong một phần	Nhiều quan sát của cùng một đối tượng
Theo thời gian	Cửa sổ mở rộng hoặc trượt, không trộn	Chuỗi thời gian, dữ liệu có thứ tự

Đánh đổi khi chọn k. k nhỏ → chạy nhanh nhưng mỗi lần chỉ dùng ít dữ liệu để huấn luyện, ước lượng hiệu năng bị **thiên lệch bi quan**. k lớn → huấn luyện gần như trên toàn bộ dữ liệu nên ít thiên lệch, nhưng **tốn thời gian** và các lần đánh giá tương quan mạnh với nhau. **k = 5 hoặc 10 là thoả hiệp được dùng phổ biến nhất.**

KIỂM ĐỊNH CHÉO LỒNG NHAU

Nếu dùng cùng một vòng kiểm định chéo để vừa chọn siêu tham số vừa báo cáo hiệu năng, con số báo cáo sẽ lạc quan — vì siêu tham số đã được chọn sao cho hợp với chính những phần dữ liệu đó.

Kiểm định chéo lồng nhau (nested cross-validation) tách hai việc này thành hai vòng:

vòng trong — chạy k-fold trên phần huấn luyện để **chọn siêu tham số**;

vòng ngoài — chạy k-fold để **đánh giá** toàn bộ quy trình, kể cả bước chọn siêu tham số vừa rồi.

Kết quả là một ước lượng không thiên lệch về hiệu năng của cả quy trình xây dựng mô hình, chứ không riêng của một mô hình cụ thể.

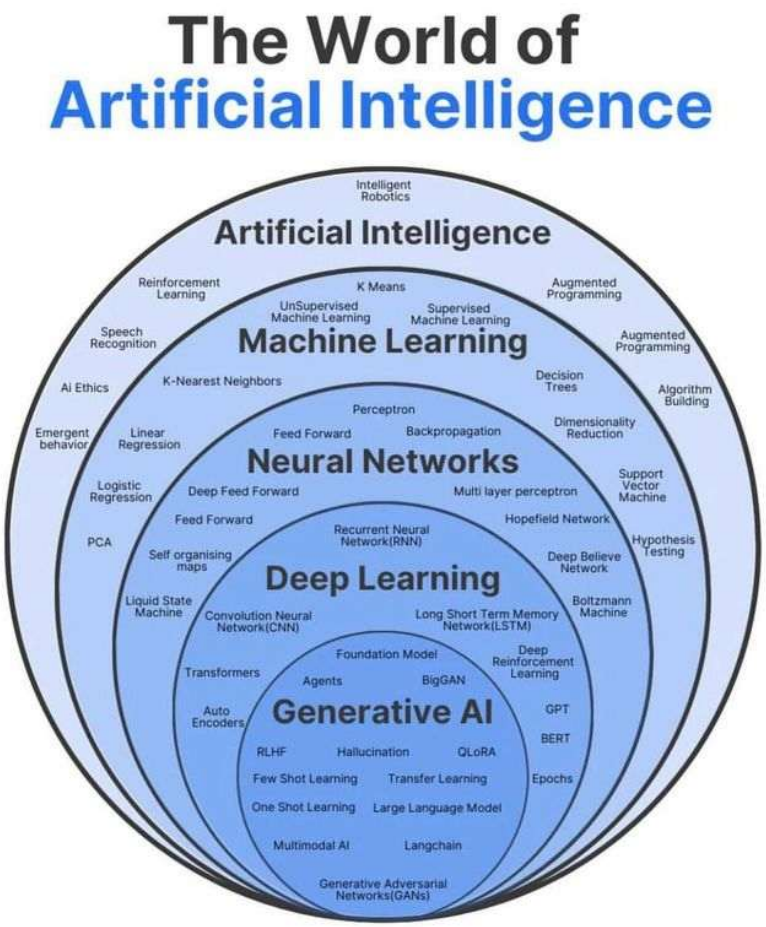
Chi phí: nếu vòng ngoài 5 phần và vòng trong 5 phần thì phải huấn luyện 25 lần cho mỗi bộ siêu tham số. Thường chỉ dùng khi dữ liệu ít và kết luận cần độ tin cậy cao.

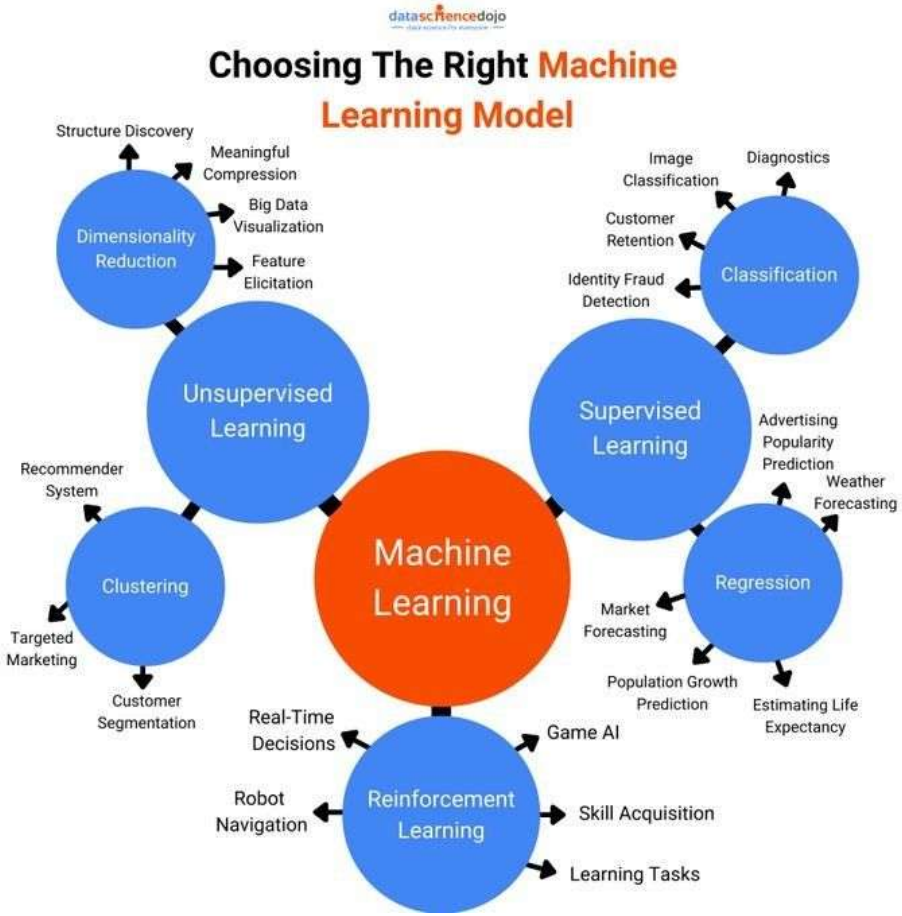
SO SÁNH HAI CÁCH CHIA

Tiêu chí	Chia ngẫu nhiên một lần	Kiểm định chéo k-fold
Số lần huấn luyện	1	k (thường 5 hoặc 10)
Chi phí tính toán	Thấp	Cao gấp k lần
Dùng hết dữ liệu?	Không — phần kiểm định bị bỏ ra	Có — mọi quan sát đều được dùng
Độ ổn định ước lượng	Phụ thuộc một lần bốc thăm	Ổn định hơn nhiều
Cho biết độ biến động?	Không	Có — qua độ lệch chuẩn của k lần
Phù hợp khi	Dữ liệu rất lớn, mô hình đắt	Dữ liệu vừa và nhỏ

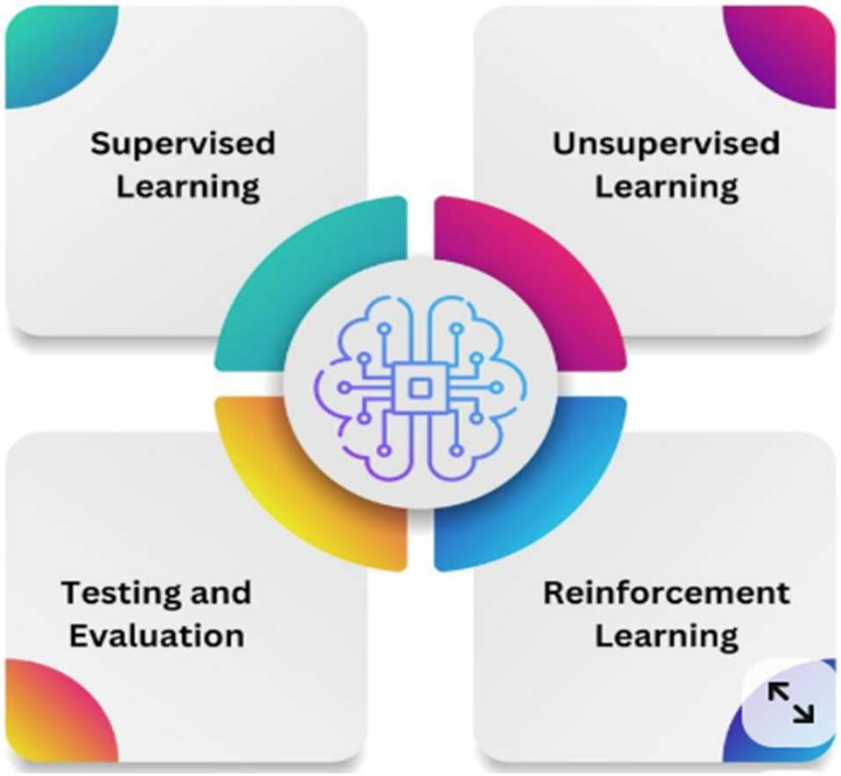
Không loại trừ nhau. Cách làm chuẩn trong thực tế là **kết hợp cả hai**: tách tập kiểm tra ra một lần bằng chia ngẫu nhiên, rồi dùng kiểm định chéo trên phần còn lại để chọn mô hình.

3. Các mô hình học máy





Các loại mô hình học máy



Học máy có giám sát là các thuật toán áp dụng khi sử dụng các biến đầu vào để dự đoán hay phân loại đầu ra dựa vào dữ liệu có nhãn (labeled data) của biến đầu ra

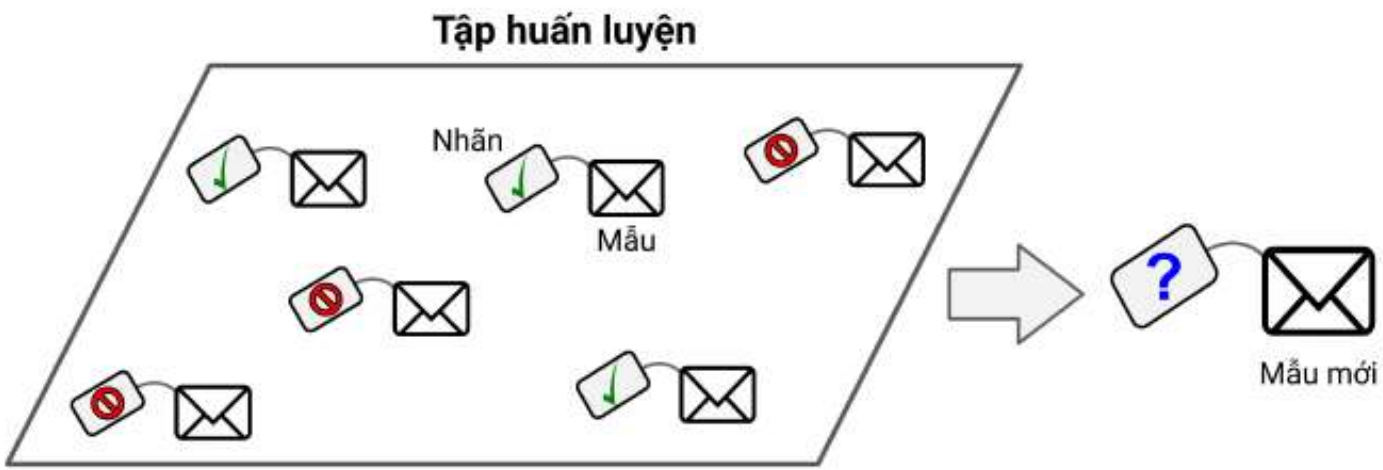
Học máy giám sát (supervised learning)

Hồi Quy (Regression)

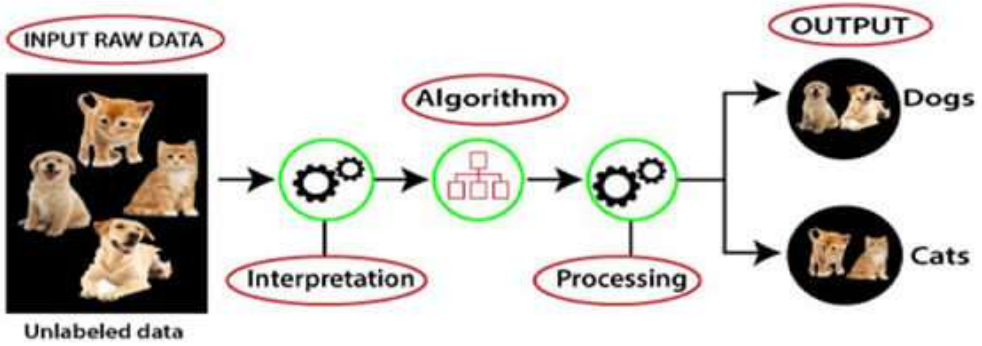
- Linear Regression
- Logistic Regression
- Lasso Regression
- Neural network

Phân loại (Classification)

- Naive Bayes
- Decision tree
- Random Forest
- Neural network
- SVM

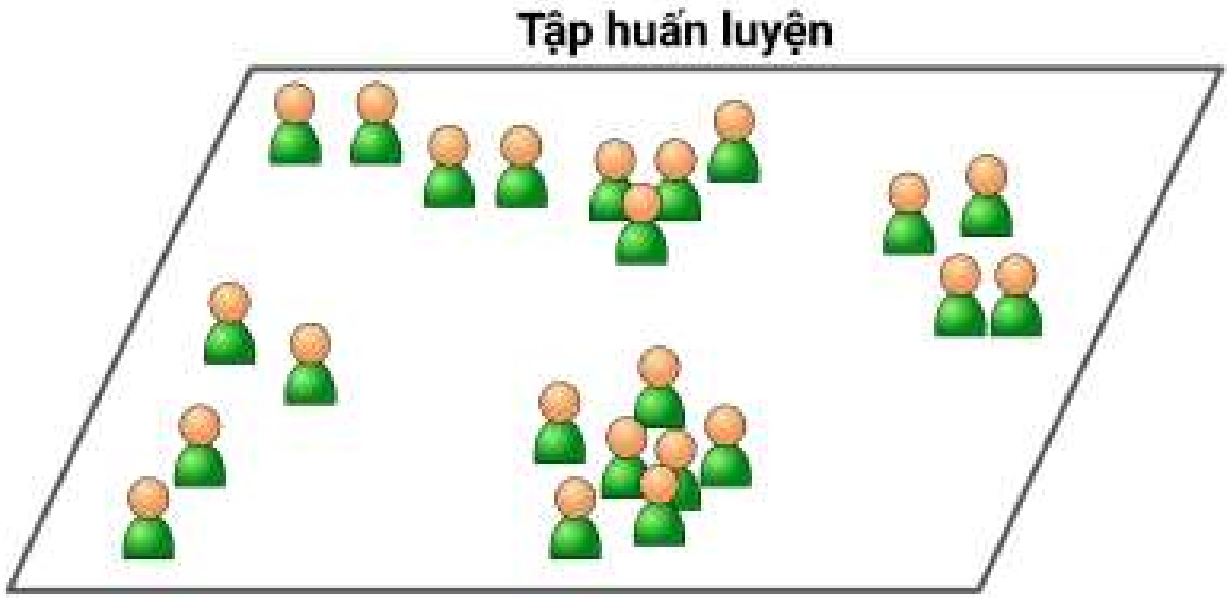

Tập huấn luyện
Nhãn
Mẫu
?
Mẫu mới

Học máy không giám sát

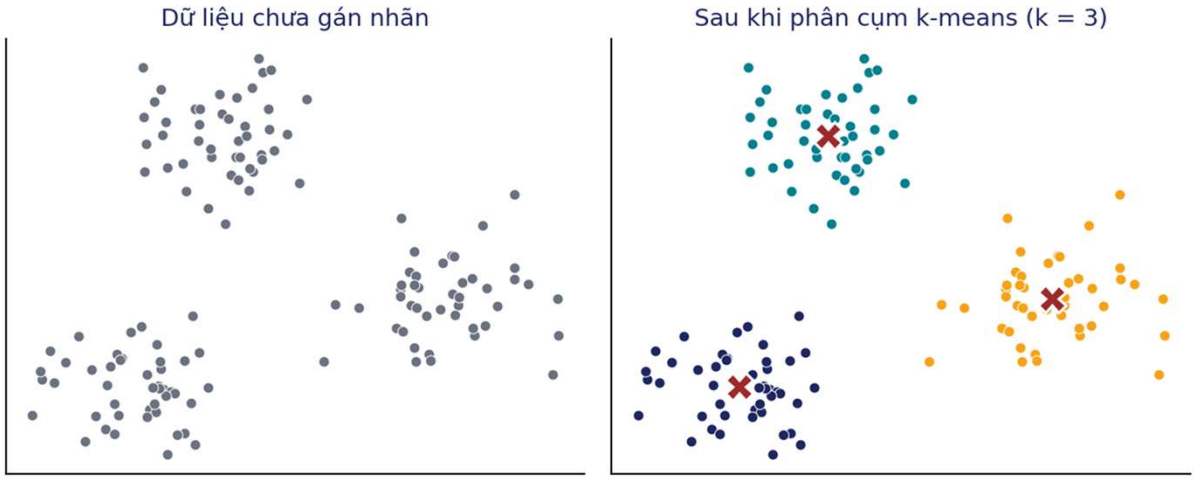


Học máy không giám sát là các thuật toán áp dụng khi chỉ có biến đầu vào và không có biến đầu ra dựa vào dữ liệu không có nhãn (unlabeled data) của biến đầu ra

- Clustering
  - k-Means
  - Hierarchical Cluster Analysis (HCA)
  - Expectation Maximization
- Visualization and dimensionality reduction
  - Principal Component Analysis (PCA)
  - Kernel PCA
  - Locally-Linear Embedding (LLE)
  - t-distributed Stochastic Neighbor Embedding (t-SNE)
- Association rule learning
  - Apriori
  - Eclat


Tập huấn luyện

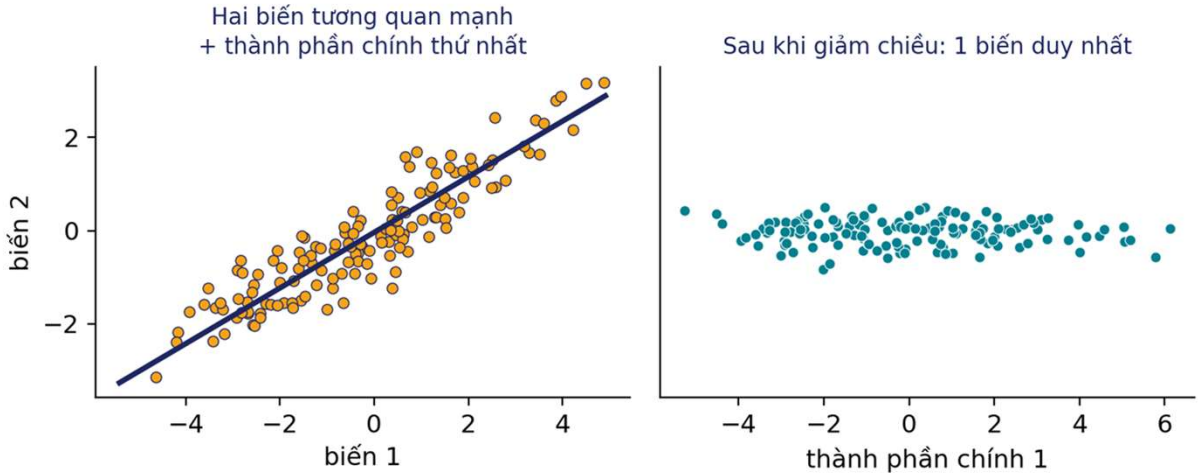
HỌC KHÔNG GIÁM SÁT: PHÂN CỤM



k-means chia dữ liệu thành k cụm sao cho các quan sát trong cùng một cụm gần nhau nhất. Ứng dụng điển hình: phân khúc khách hàng, nhóm chi nhánh có hành vi tương tự, nén ảnh.

Không có "đáp án đúng" để đối chiếu — chất lượng phân cụm phải được đánh giá bằng chỉ số nội tại và, quan trọng hơn, bằng **ý nghĩa nghiệp vụ** của các cụm tìm được.

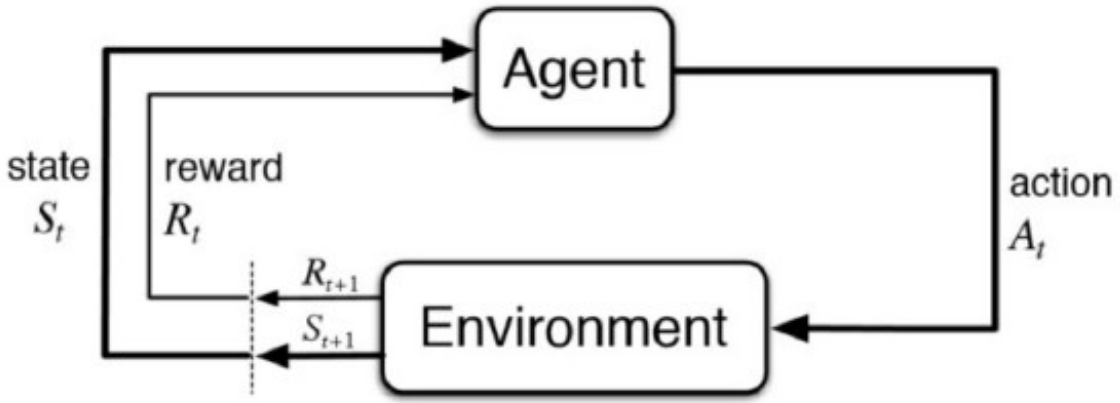
HỌC KHÔNG GIÁM SÁT: GIẢM CHIỀU



Phân tích thành phần chính (PCA) tìm một số ít chiều mới, là tổ hợp tuyến tính của các biến gốc, giữ lại phần lớn thông tin. Dùng để trực quan hoá, để nén dữ liệu, và để xử lý hiện tượng nhiều biến tương quan mạnh với nhau.

Cái giá phải trả: các chiều mới **không còn ý nghĩa kinh tế trực tiếp** — "thành phần chính thứ nhất" không phải là một biến ta có thể giải thích cho khách hàng.

Học củng cố Reinforcement là một nhánh của học máy, trong đó một tác nhân (agent) học cách đưa ra quyết định bằng cách tương tác với môi trường (environment) để tối ưu hóa phần thưởng (reward).



3. Các mô hình học máy

CHỌN MÔ HÌNH NÀO?

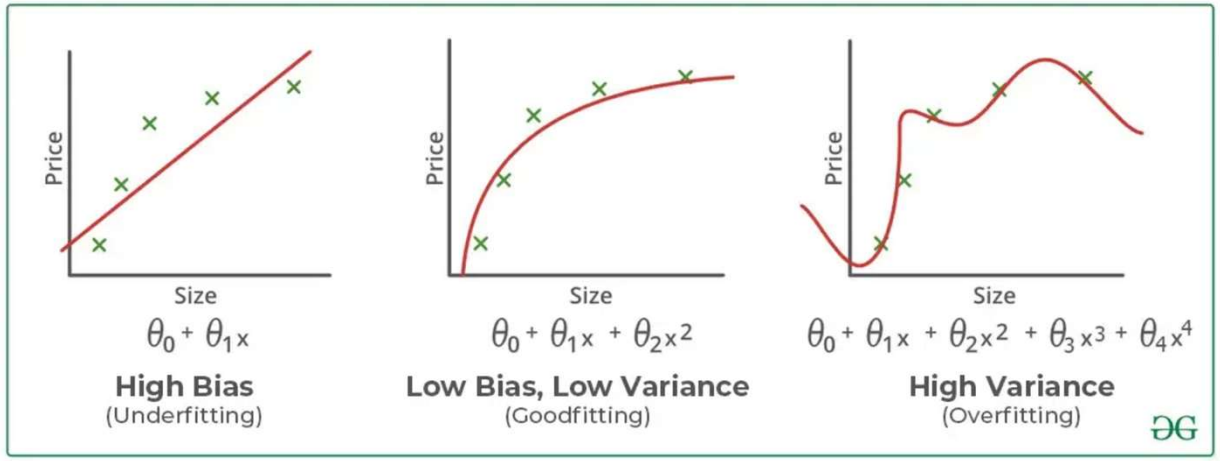
Tình huống	Hướng lựa chọn
Dữ liệu bảng, cần giải thích rõ ràng	Hồi quy tuyến tính / logistic, cây quyết định
Dữ liệu bảng, ưu tiên độ chính xác	Rừng ngẫu nhiên, gradient boosting
Ảnh, âm thanh, video	Mạng nơ-ron sâu (CNN)
Văn bản, ngôn ngữ tự nhiên	Transformer, mô hình ngôn ngữ lớn
Không có nhãn, muốn tìm nhóm	k-means và các thuật toán phân cụm khác
Quá nhiều biến tương quan	PCA hoặc các phương pháp giảm chiều
Dữ liệu rất ít	Mô hình đơn giản, kiểm định chéo, thêm dữ liệu

Nguyên tắc làm việc: **luôn bắt đầu bằng mô hình đơn giản nhất làm mốc so sánh**, rồi mới thử mô hình phức tạp hơn — và chỉ giữ mô hình phức tạp nếu nó thật sự tốt hơn đáng kể.

Các Đặc trưng Không liên quan

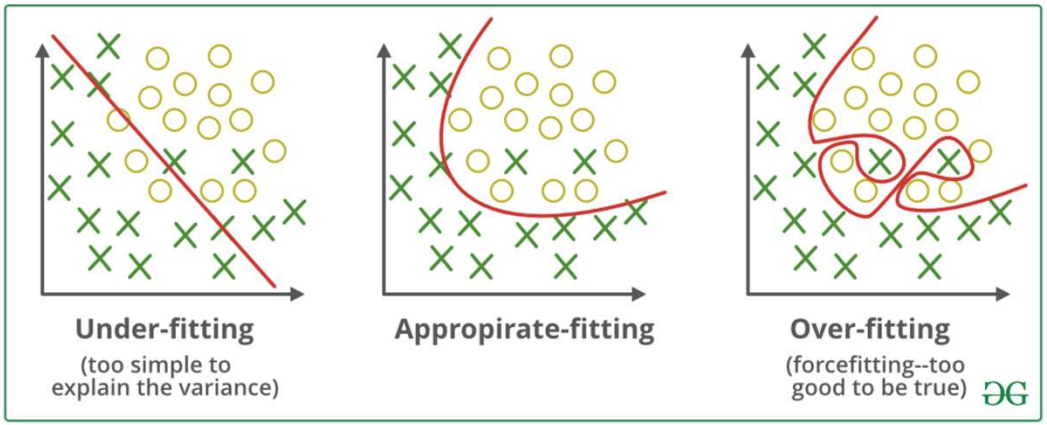
Có một câu nói là "rác vào, rác ra". Hệ thống chỉ có thể học được nếu dữ liệu huấn luyện chứa đủ các đặc trưng liên quan và không quá nhiều các đặc trưng không liên quan. Một phần quan trọng dẫn đến một dự án Học Máy thành công là xây dựng được một bộ đặc trưng tốt để huấn luyện. Quy trình này được gọi là *thiết kế đặc trưng* (*feature engineering*) và bao gồm các bước sau:

- *Lựa chọn đặc trưng* (lựa chọn những đặc trưng hữu ích nhất từ các đặc trưng sẵn có để huấn luyện)
- *Trích xuất đặc trưng* (kết hợp các đặc trưng sẵn có để tạo ra một đặc trưng hữu ích hơn, và như đã đề cập phía trên, các thuật toán giảm chiều có thể có ích)
- Tạo ra các đặc trưng mới bằng cách thu thập thêm dữ liệu



•**Bias (Độ chệch)**:
Bias là sai số xảy ra do mô hình quá đơn giản hóa vấn đề (underfitting). Một mô hình có bias cao thường bỏ qua các mối quan hệ phức tạp trong dữ liệu, dẫn đến việc dự đoán không chính xác trên cả tập huấn luyện và tập kiểm tra. Ví dụ, một mô hình tuyến tính áp dụng cho dữ liệu phi tuyến tính sẽ có bias cao vì không thể nắm bắt được sự phức tạp của dữ liệu.
•**Variance (Phương sai)**:
Variance đo lường mức độ nhạy cảm của mô hình đối với các thay đổi nhỏ trong dữ liệu huấn luyện. Một mô hình có variance cao (overfitting) sẽ học quá chi tiết các đặc điểm của dữ liệu huấn luyện, bao gồm cả nhiễu, dẫn đến việc hoạt động tốt trên tập huấn luyện nhưng kém trên tập kiểm tra. Ví dụ, một cây quyết định quá sâu có thể ghi nhớ dữ liệu huấn luyện thay vì học các mẫu tổng quát.

Dưới khớp và chưa khớp



Underfitting and Overfitting

Dưới khớp (underfitting). Mô hình quá đơn giản, sai cả trên tập huấn luyện lẫn tập kiểm tra. Cách chữa: tăng độ phức tạp, thêm đặc trưng.

Quá khớp (overfitting). Mô hình học thuộc cả phần nhiễu, rất tốt trên tập huấn luyện nhưng kém trên dữ liệu mới. Cách chữa: thêm dữ liệu, giảm độ phức tạp, dùng phạt (regularisation), dừng sớm.

Mục tiêu của học máy **không phải** là khớp thật tốt dữ liệu đã có, mà là **dự đoán tốt dữ liệu chưa từng thấy**. Đây là khác biệt căn bản so với thống kê mô tả.

Underfitting (Dưới khớp)

•Định nghĩa:

Underfitting xảy ra khi mô hình **quá đơn giản** để học được cấu trúc từ dữ liệu. Nó không nắm bắt được mối quan hệ giữa các biến đầu vào và đầu ra một cách đầy đủ.

•Nguyên nhân phổ biến:

- •Mô hình quá đơn giản (ví dụ: dùng hồi quy tuyến tính cho một bài toán phi tuyến).
- •Dữ liệu chưa được xử lý hoặc chưa đủ đặc trưng (feature).
- •Huấn luyện chưa đủ thời gian (training chưa đầy đủ).

•Biểu hiện:

- •Sai số cao trên cả tập huấn luyện và tập kiểm tra.
- •Mô hình không học được điều gì có ích từ dữ liệu.

•Ví dụ:

Dự đoán điểm số sinh viên chỉ dựa vào số lần đến lớp, mà bỏ qua các yếu tố như thời gian học, điểm bài tập, v.v.

Overfitting (Quá khớp)

•Định nghĩa:

Overfitting xảy ra khi mô hình **quá phức tạp**, học quá kỹ dữ liệu huấn luyện, bao gồm cả nhiễu và những điểm không đại diện cho xu hướng thực tế.

•Nguyên nhân phổ biến:

- Mô hình quá phức tạp (nhiều lớp, nhiều tham số).
- Quá ít dữ liệu huấn luyện.
- Không sử dụng các kỹ thuật regularization hoặc validation.

•Biểu hiện:

- Sai số thấp trên tập huấn luyện.
- Sai số cao trên tập kiểm tra → mô hình hoạt động kém trên dữ liệu mới.

•Ví dụ:

Mô hình nhớ từng điểm dữ liệu thay vì học ra quy luật → như học vẹt, không tổng quát hóa được.

Optimal Fitting (Khớp tối ưu – vừa đủ)

•Định nghĩa:

Đây là trạng thái lý tưởng, nơi mô hình học được đúng mức từ dữ liệu: đủ để nắm bắt xu hướng tổng thể mà không học theo nhiễu.

•Biểu hiện:

- Sai số thấp trên cả tập huấn luyện và kiểm tra.
- Mô hình có khả năng **tổng quát hóa tốt** (generalize well) trên dữ liệu chưa thấy.

•Làm thế nào để đạt được optimal fitting?

- Dùng cross-validation.
- Chọn mô hình có độ phức tạp phù hợp.
- Dùng kỹ thuật regularization.
- Cung cấp đủ dữ liệu huấn luyện.

Các bước cơ bản thực hiện mô hình machie learning

1. Xác định bài toán
2. Thu thập dữ liệu – Gathering data/Data collection
3. Tiền xử lý dữ liệu – Data preprocessing
   - Làm sạch dữ liệu – Data cleaning (Loại bỏ hoặc xử lý giá trị thiếu, giá trị ngoại lệ)
   - Chuyển đổi dữ liệu – Data transformation (Label Encoding, One-Hot Encoding)
   - Chuẩn hóa dữ liệu – Data normalization (Standardization, Normalization)
   - Trích xuất đặc trưng – Feature extraction (Feature selection, Feature engineering)
4. Phân chia tập dữ liệu thành tập train và tập test
5. Lựa chọn và huấn luyện mô hình (sử dụng tập train)
6. Huấn luyện mô hình
7. Đánh giá mô hình – Model evaluation (sử dụng tập test)
   - Phân loại: Accuracy, Precision, Recall, F1-score, AUC
   - Hồi quy: RMSE, MAE, R^2
8. Hiệu chỉnh mô hình
   - Grid Search
   - Random Search
   - Cross-validation
9. Triển khai mô hình: Dự báo, phân lớp

3.1. Mô hình hồi quy

Xét mối quan hệ giữa $x = (x_1, x_2, ..., x_n)$ và y.

$x = (x_1, x_2, ..., x_n)$ gọi là biến độc lập, biến giải thích hoặc các đặc tính

y gọi là biến phụ thuộc, biến cần được giải thích hoặc biến mục tiêu.

Giả sử dạng mô hình

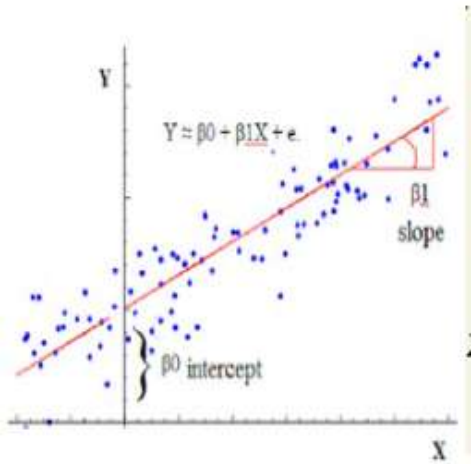
$$\hat{y} = \beta_0 + \beta_1 x_1 + ... + \beta_p x_p$$

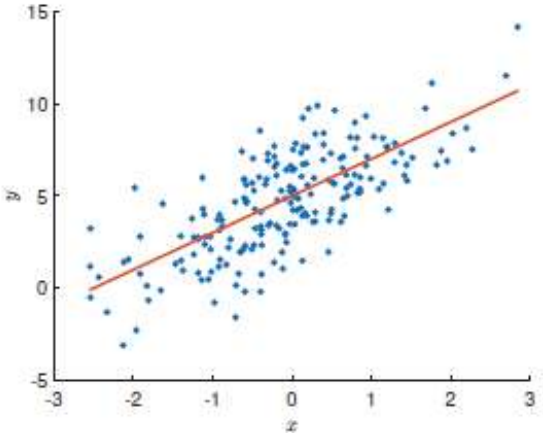
Cần tìm các tham số $\beta_0, \beta_1, ..., \beta_p$ sao cho hàm loss function nhận giá trị nhỏ nhất:

$$Loss(y, \bar{y}) = (y - \hat{y})^2$$

Hồi quy tuyến tính

- Mối tương quan xấp xỉ theo dạng đường thẳng
- Đơn biến: $y = \beta_0 + \beta_1 x + \varepsilon$
- Đa biến: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + ... + \varepsilon$



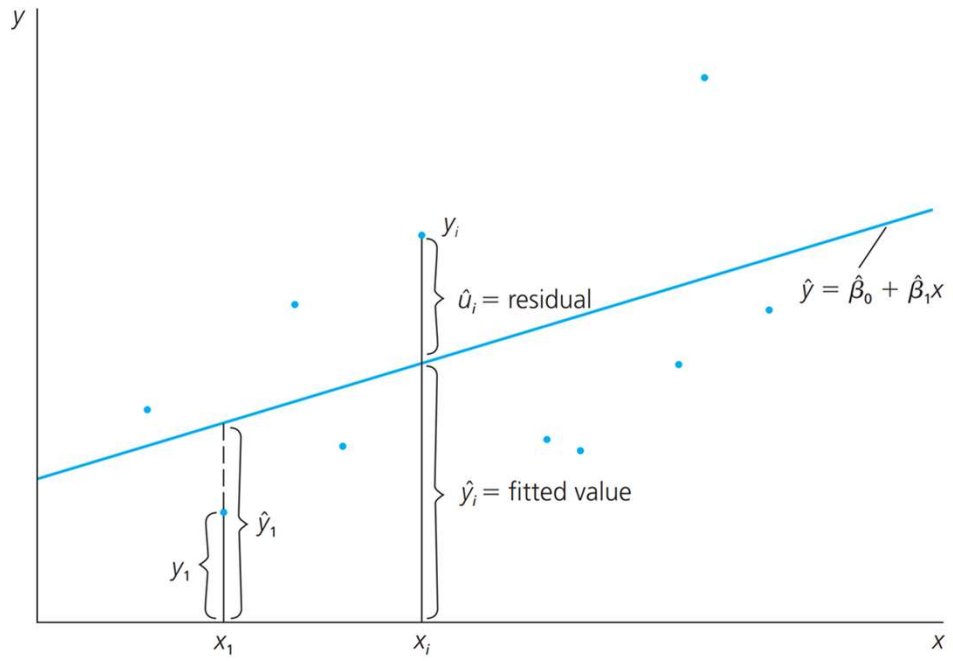


Tìm các tham số sao cho tổng bình phương phần dư là nhỏ nhất

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \qquad \bar{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i$$

$$x_i = X_i - \bar{X} \qquad y_i = Y_i - \bar{Y}$$

$$\hat{\beta}_2 = \frac{\sum_1^n x_i y_i}{\sum_1^n x_i^2} \qquad \hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$$



Đánh giá mô hình

- **Mean Absolute Error (MAE)** – Sai số tuyệt đối trung bình

MAE đo sai số trung bình tuyệt đối giữa giá trị thực tế và giá trị dự báo của mô hình. Đây là một chỉ số dễ hiểu và không bị ảnh hưởng nhiều bởi các sai số lớn bất thường.

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- **Mean Squared Error (MSE)** – Sai số bình phương trung bình

MSE phạt sai số lớn nặng hơn nhờ bình phương phần sai số. Đây là một trong những chỉ số phổ biến nhất để huấn luyện và đánh giá mô hình hồi quy.

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- **Root Mean Squared Error (RMSE)** – Căn bậc hai của sai số bình phương trung bình

RMSE giúp đưa kết quả sai số về cùng đơn vị với dữ liệu đầu vào, dễ diễn giải và thường được dùng trong báo cáo kết quả.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

- **R-squared (R^2)** – Hệ số xác định

Chỉ số R^2 cho biết mức độ mà mô hình hồi quy giải thích được phương sai trong dữ liệu. R^2 nằm trong khoảng từ 0 đến 1, càng gần 1 càng tốt.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Trong đó, $\bar{y}$ là giá trị trung bình của biến mục tiêu y.

Cây quyết định (Decision Tree Regression)

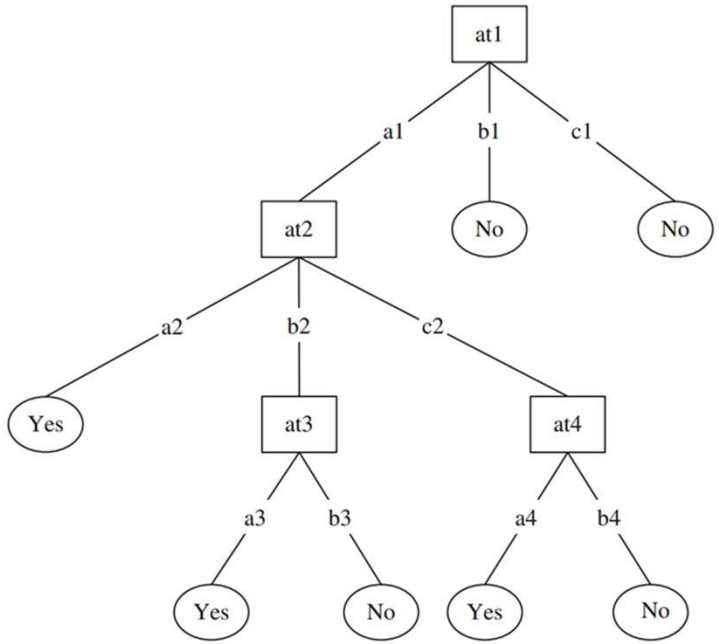
Decision Tree Hồi quy là mô hình học máy dựa trên cấu trúc cây phân tách để dự đoán giá trị số liên tục (liên quan đến bài toán hồi quy). Mô hình chia dữ liệu thành các vùng nhỏ, sao cho mỗi vùng có giá trị đầu ra càng đồng nhất càng tốt.

Thành phần chính của mỗi cây bao gồm các nút (node) và các nhánh, ba bước cơ bản của thuật toán là chia tách cây, dừng và điều chỉnh.

Các loại nút: (a) Nút gốc, còn được gọi là nút quyết định, đại diện cho một lựa chọn sẽ dẫn đến việc chia nhỏ tất cả các bản ghi thành hai hoặc nhiều tập hợp con loại trừ lẫn nhau. (b) Các nút bên trong, đại diện cho một trong những lựa chọn có thể có tại một thời điểm trong cấu trúc cây; cạnh trên của nút được kết nối với nút cha của nó và cạnh dưới được kết nối với các nút con hoặc nút lá của nó. (c) Nút lá, còn được gọi là nút cuối, biểu thị kết quả cuối cùng các quyết định hoặc sự kiện.

Nguyên lý hoạt động:

- Tìm điểm chia (split) trên một biến đầu vào sao cho giảm sai số dự báo lớn nhất (thường dùng tiêu chí giảm MSE).
- Chia nhánh dữ liệu theo điều kiện.
- Lặp lại quá trình này cho đến khi đạt điều kiện dừng (số lượng mẫu tối thiểu, độ sâu cây, hoặc sai số nhỏ).
- Dự báo bằng giá trị trung bình của nhánh lá mà dữ liệu thuộc vào.



📈 Ưu điểm:

Dễ hiểu và trực quan hóa (diễn giải tốt)

Xử lý dữ liệu phi tuyến rất tốt

Không yêu cầu chuẩn hóa dữ liệu

Tự động chọn biến quan trọng

⚠️ Nhược điểm:

Dễ overfitting nếu cây quá sâu

Nhạy cảm với dữ liệu nhiễu

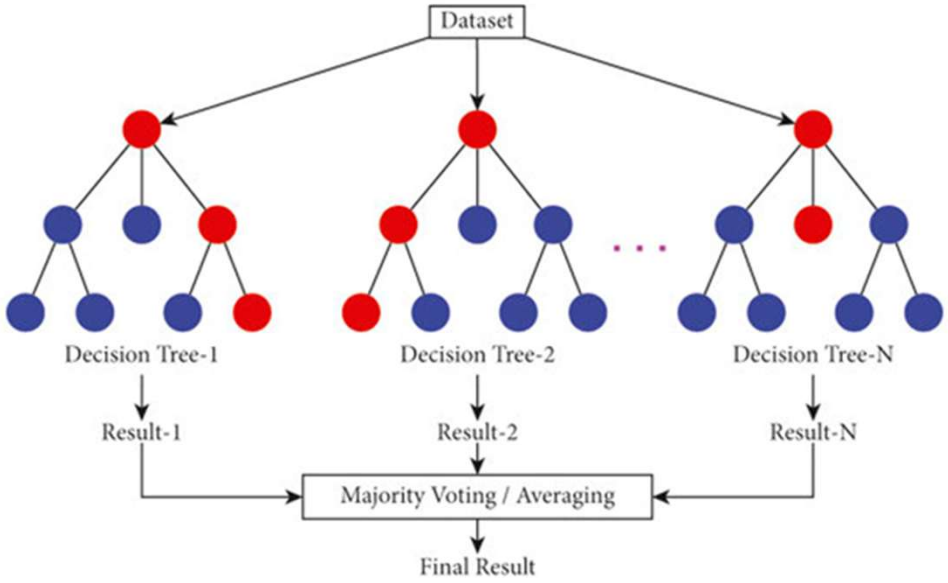
Khó tổng quát hóa tốt trên tập dữ liệu mới

Mô hình rừng ngẫu nhiên (Random forest - RF)

Mô hình rừng ngẫu nhiên là một trong kỹ thuật mở rộng trên cây quyết định phát triển từ thuật toán Bagging, được đề xuất lần đầu tiên bởi Breiman và cộng sự (1984). Random forest mở rộng phương pháp cây quyết định bằng cách lấy ngẫu nhiên một lượng lớn số lượng cây từ dữ liệu. Tại mỗi nút của cây, một tập hợp con của các biến đầu vào được chọn ngẫu nhiên để tạo các nút của cây. Vì các biến đầu vào cho mỗi cây quyết định được chọn một cách ngẫu nhiên, nó làm giảm sự tương quan giữa các cây và tránh vấn đề quá mức (overfitting).

Nguyên lý hoạt động:

- Bootstrap sampling: Lấy mẫu ngẫu nhiên có hoàn lại từ tập huấn luyện để tạo từng cây con.
- Random feature selection: Tại mỗi nút phân chia, chỉ xét một tập con ngẫu nhiên các biến thay vì toàn bộ biến.
- Huấn luyện nhiều cây Decision Tree (thường từ 100 đến 1000 cây).
- Dự báo đầu ra là trung bình dự báo của tất cả các cây



📈 Ưu điểm:

Hiệu quả cao, độ chính xác tốt hơn Decision Tree đơn lẻ

Giảm overfitting nhờ kỹ thuật bagging

Xử lý tốt dữ liệu phi tuyến

Tự động đánh giá mức độ quan trọng của biến (feature importance)

⚠️ Nhược điểm:

Khó giải thích hơn Decision Tree đơn lẻ

Tốn tài nguyên tính toán nếu nhiều cây

Thời gian huấn luyện lâu hơn

3.2. Mô hình phân lớp

Mô hình phân lớp là mô hình học máy được sử dụng để dự đoán nhãn đầu ra dạng phân loại (categorical).

Ví dụ:

Khách hàng có vỡ nợ / không vỡ nợ

Email là spam / không spam

Giao dịch là gian lận / không gian lận

Hồi quy logistic

Hồi quy logistic là một trong những phương pháp thống kê phổ biến nhất dùng để phân lớp các biến nhị phân được sử dụng để dự đoán xác suất một đối tượng thuộc vào một trong hai lớp (ví dụ: vỡ nợ / không vỡ nợ).

- Ưu điểm của Logistic Regression:

Dễ hiểu, dễ giải thích
Hiệu quả với dữ liệu tuyến tính
Tính toán nhanh
Có thể thêm Regularization (L1, L2)

- Nhược điểm:

Hiệu suất kém nếu quan hệ phi tuyến tính
Nhạy cảm với outliers
Giả định tuyến tính giữa logit và biến đầu vào

$$\frac{p}{1-p} = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n}$$

🧠 Ý tưởng chính:

Thay vì dự đoán trực tiếp giá trị liên tục như hồi quy tuyến tính, Logistic Regression dự đoán **xác suất** thông qua **hàm sigmoid**:

$$P(y = 1|x) = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{trong đó } z = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

- $\sigma(z)$: hàm sigmoid, biến đầu ra về khoảng (0, 1)
- $y = 1$: lớp dương (positive class)
- β_i: hệ số ước lượng

⚖️ Ngưỡng phân loại:

Sau khi tính được xác suất, cần chọn **ngưỡng (threshold)** để quyết định phân lớp:

$$\hat{y} = \begin{cases} 1, & \text{nếu } P(y=1|x) \geq \text{threshold} \\ 0, & \text{ngược lại} \end{cases}$$

- Mặc định: threshold = 0.5
- Có thể điều chỉnh để tối ưu độ nhạy, độ đặc hiệu...

Ma trận nhầm lẫn

		Giá trị thật	
		1	0
Kết quả	1	TP	FP
	0	FN	TN

TP (true positive) là số dự đoán tích cực, được dự báo đúng là tích cực.

TN (true negative) là số dự đoán âm và mô hình được dự đoán đúng

FP (false positive) (dương tính giả) là số lượng trường hợp thực tế là âm, nhưng mô hình dự đoán sai là dương, FN (false negative) (âm tính giả) là số ượng trường hợp thực tế là dương, nhưng mô hình lại dự đoán sai là âm.

📌 Các chỉ số đánh giá quan trọng:

- **Accuracy (Độ chính xác)**

  Tỷ lệ dự đoán đúng trên toàn bộ mẫu:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (Độ chính xác dương)**

  Trong các dự đoán dương, bao nhiêu là đúng:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong các trường hợp thực tế dương, mô hình bắt đúng bao nhiêu:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1 Score**

  Trung bình điều hòa giữa Precision và Recall:

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **AUC - ROC (Area Under Curve - Receiver Operating Characteristic)**

  Đánh giá khả năng phân biệt giữa các lớp; càng gần 1 càng tốt.

HEADER 1

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Header 2

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam

HEADER 1

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat.

Header 1

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat.

Header 2

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat.

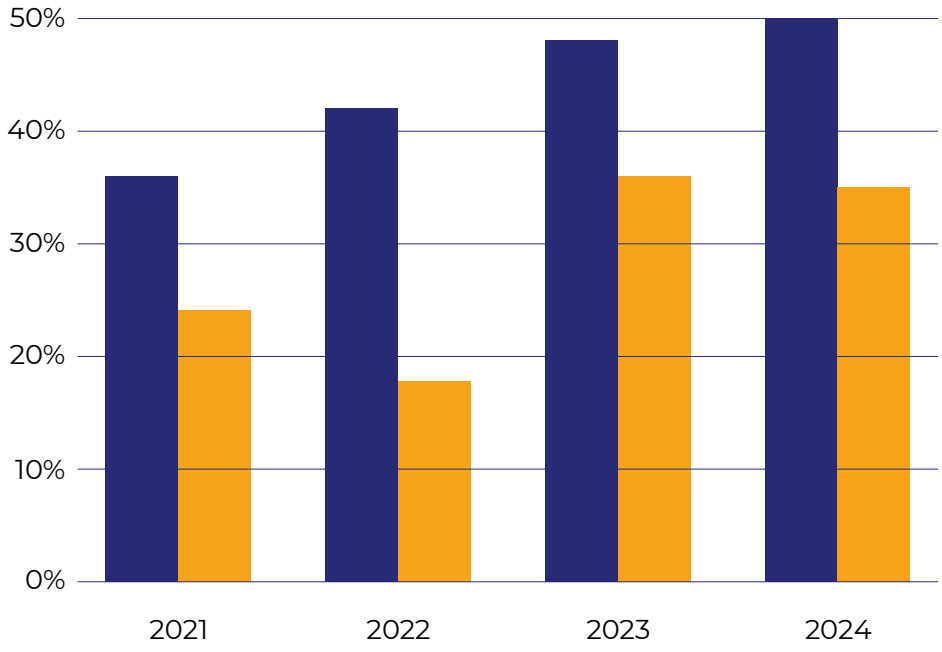
HEADER 1

Header 2

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam



HEADER 1

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

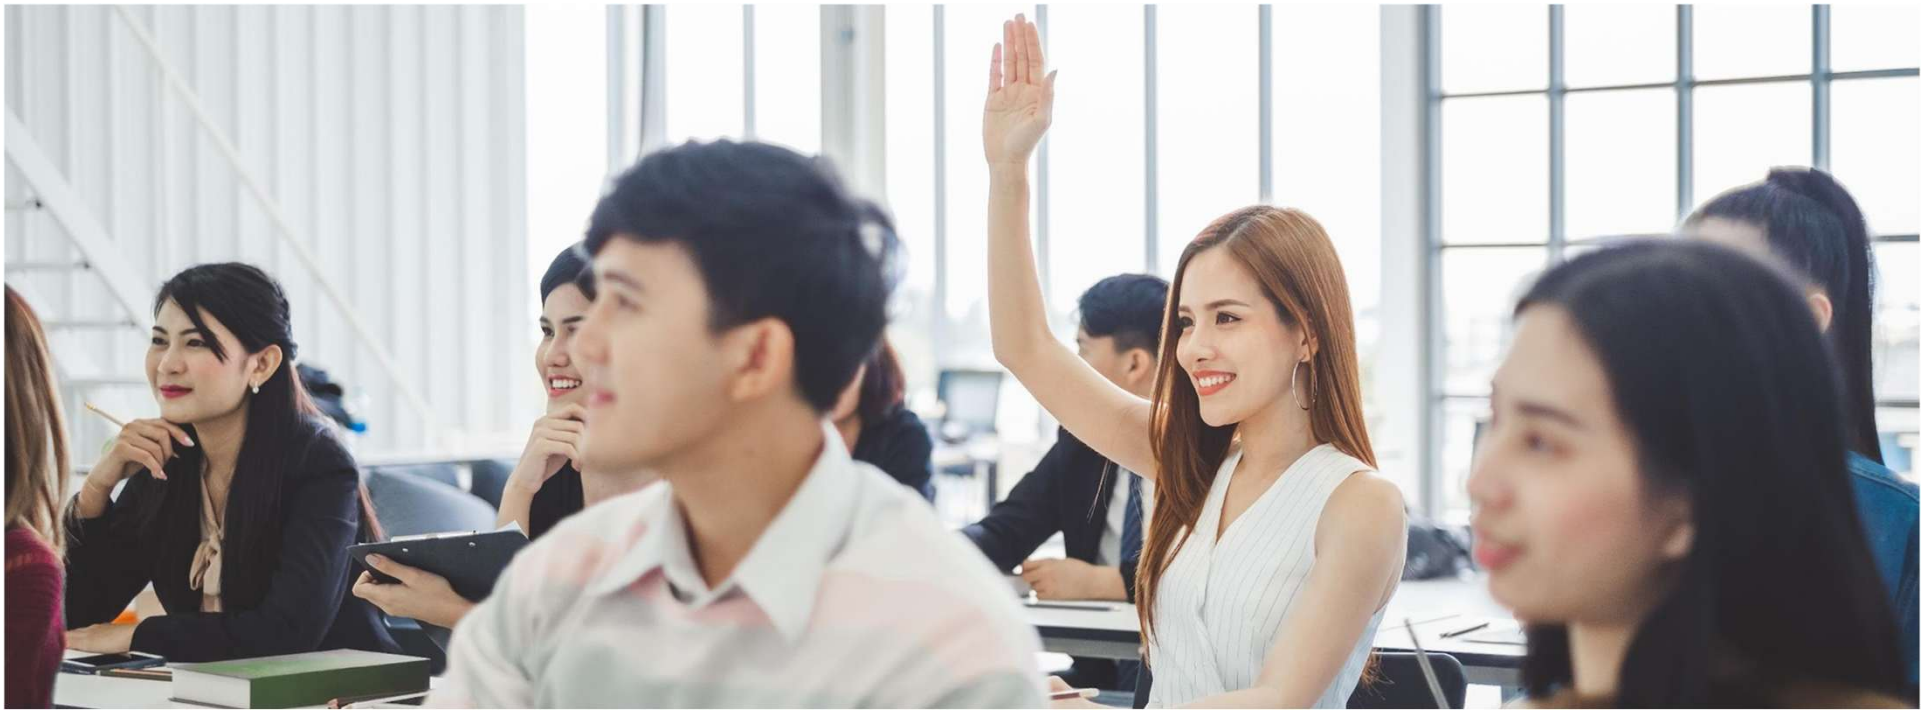
Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat.

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat.

CHAPTER 3

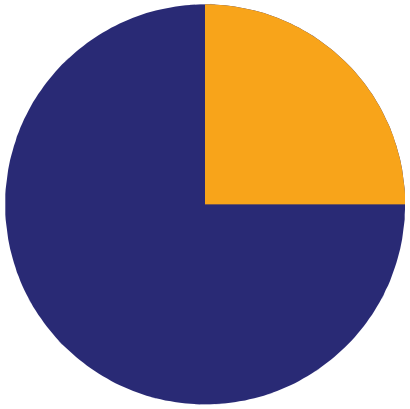


Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat.

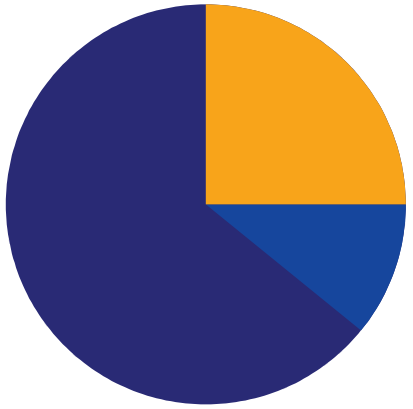
HEADER 1

Lorem ipsum dolor sit amet, consectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam, quis nostrud exerci tation ullamcorper suscipit lobortis nisl ut aliquip ex ea commodo consequat. Duis autem vel eum iriure dolor in hendrerit in vulputate velit esse molestie consequat, vel illum dolore eu feugiat nulla facilisis at vero eros et accumsan et iusto odio dignissim qui blandit praesent luptatum zzril delenit augue duis dolore te feugait nulla facilisi.

Lorem ipsum dolor sit amet, cons ectetuer adipiscing elit, sed diam nonummy nibh euismod tincidunt ut laoreet dolore magna aliquam erat volutpat.



Lorem ipsum dolor sit amet
Lorem ipsum dolor sit amet



Lorem ipsum dolor sit amet
Lorem ipsum dolor sit amet
Lorem ipsum dolor sit amet

THANK YOU FOR WATCHING

HỌC VIỆN NGÂN HÀNG
BANKING ACADEMY OF VIETNAM

Học viện Ngân hàng
12 P. Chùa Bộc, P. Quang Trung,
Q. Đống Đa, TP. Hà Nội

T: 1900 561 595 **F:** 1900 561 595
E: truyenthong@hvnh.edu.vn
W: www.hvnh.edu.vn