HỌC VIỆN NGÂN HÀNG
BANKING ACADEMY OF VIETNAM



XỬ LÝ VÀ KHÁM PHÁ DỮ LIỆU

MỤC TIÊU



Vai trò của phân tích kinh doanh

Hiểu khái niệm cơ bản về phân tích kinh doanh và vai trò của nó trong ra quyết định



Khám phá dữ liệu

Các bước làm sạch dữ liệu, thống kê mô tả, trực quan hóa dữ liệu



Khai phá dữ liệu và Thống kê suy luận

Sử dụng các phương pháp trực quan hóa dữ liệu để đưa ra thông tin, kiểm định các giải thuyết

1. Phân tích kinh doanh là gì?

Quá trình sử dụng dữ liệu, phương pháp định lượng và công nghệ để **chuyển dữ liệu thành quyết định kinh doanh có căn cứ**.

Business Intelligence

Báo cáo, dashboard, dữ liệu quá khứ

"Chuyện gì đã xảy ra?"

Business Analytics

Mô hình hoá, suy diễn, dự báo, đề xuất

"Vì sao? Sẽ ra sao? Nên làm gì?"

Data Science

Phương pháp và công nghệ xử lý dữ liệu

"Khai thác dữ liệu bằng cách nào?"

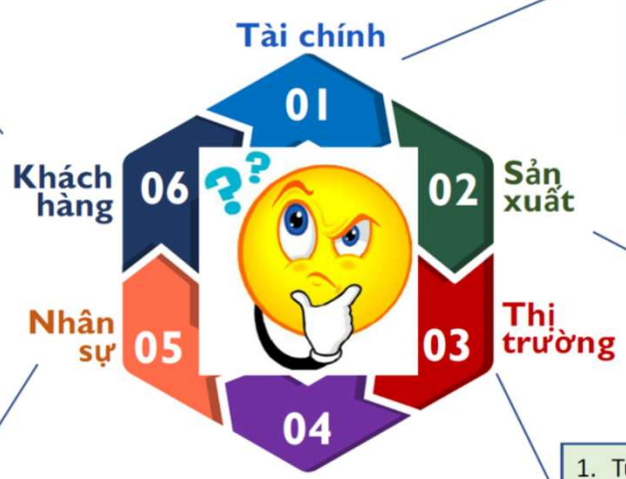
Ba thành tố không thể tách rời

Dữ liệu → Mô hình → Quyết định. Thiếu thành tố thứ ba, phân tích chỉ còn là một bài tập kỹ thuật.

PHÂN TÍCH KINH DOANH TRONG THỰC TIỄN

🏢 Các lĩnh vực ứng dụng:

- 📊 Phân tích tài chính
- 👥 Phân tích nhân sự (HR)
- 🛒 Marketing
- 🏥 Chăm sóc sức khỏe
- 🚚 Chuỗi cung ứng
- 🏛️ Chính phủ & phi lợi nhuận
- ⚽ Thể thao
- 🌐 Web & hành vi người dùng



1. Dự đoán doanh thu bán hàng
2. Phân tích lợi nhuận từ khách hàng
3. Phân tích lợi nhuận từ các sản phẩm
4. Phân tích dòng tiền
5. Phân tích các yếu tố tạo giá trị tài chính
6. Phân tích giá trị đem lại cho cổ đông

1. Lập kế hoạch dự án
2. Lập kế hoạch hoạt động
3. Bố trí cơ sở sản xuất
4. Quản lý chất lượng sản phẩm
5. Quản lý chuỗi cung ứng
6. Quản lý hàng tồn kho
7. Quản lý hoạt động dịch vụ

1. Tư vấn sản phẩm và dịch vụ
2. Phân khúc khách hàng
3. Phân tích phương tiện truyền thông xã hội
4. Phân tích khách hàng rời bỏ sản phẩm và dịch vụ

1. Phân tích khả năng
2. Phân tích năng lực
3. Phân tích kênh tuyển dụng
4. Phân tích hiệu suất của nhân viên
5. Phân tích lãnh đạo
6. Phân tích nhân viên rời bỏ công ty

1. Phân tích sự hài lòng của khách hàng
2. Phân tích vòng đời của khách hàng
3. Phân tích phân khúc khách hàng
4. Phân tích mức độ tương tác của khách hàng
5. Phân tích sự thu hút khách hàng

Vì sao phân tích kinh doanh trở thành năng lực cốt lõi?

Áp lực từ môi trường

Biên lợi nhuận mỏng, chu kỳ ra quyết định rút ngắn, khách hàng đòi hỏi cá nhân hoá, biến động vĩ mô khó lường.

Điều kiện đủ đã hình thành

Dữ liệu giao dịch và hành vi sẵn có ở quy mô lớn; chi phí tính toán, lưu trữ giảm mạnh; thư viện mô hình mã nguồn mở trưởng thành.

Dữ liệu trở thành tài sản chiến lược

Từ "sản phẩm phụ của vận hành" thành nguồn lực có thể định giá và tạo lợi thế cạnh tranh bền vững.

BẰNG CHỨNG THỰC NGHIỆM

Doanh nghiệp ra quyết định dựa trên dữ liệu đạt năng suất và hiệu quả tài chính cao hơn nhóm đối chứng, sau khi kiểm soát các yếu tố khác.

Dòng nghiên cứu về data-driven decision making (Brynjolfsson, Hitt & Kim; Brynjolfsson & McElheran)

Chuyển dịch: từ quyết định theo kinh nghiệm sang quyết định dựa trên bằng chứng.

Bốn cấp độ phân tích và vai trò tương ứng

1

MÔ TẢ

Điều gì đã xảy ra?

CÔNG CỤ

Thống kê mô tả, trực quan hoá, phân rã chỉ số

VAI TRÒ

Tạo hiểu biết chung, đo lường hiệu quả

2

CHẨN ĐOÁN

Vì sao xảy ra?

CÔNG CỤ

Kiểm định giả thuyết, suy luận nhân quả (DiD, PSM, IV)

VAI TRÒ

Xác định nguyên nhân gốc, tránh quy kết sai

3

DỰ BÁO

Điều gì sẽ xảy ra?

CÔNG CỤ

Hồi quy, chuỗi thời gian, học máy có giám sát

VAI TRÒ

Chủ động thay vì phản ứng; hoạch định nguồn lực

4

ĐỀ XUẤT

Nên làm gì?

CÔNG CỤ

Tối ưu hoá, mô phỏng, uplift modeling, học tăng cường

VAI TRÒ

Chuyển dự báo thành hành động tối ưu có ràng buộc

Giá trị và độ phức tạp tăng dần →

Bỏ qua hai cấp đầu để nhảy thẳng vào học máy thường cho mô hình chính xác về kỹ thuật nhưng vô dụng về quản trị.

Vai trò theo từng chức năng doanh nghiệp

Marketing & khách hàng

Phân khúc khách hàng, dự báo rời bỏ, giá trị vòng đời (CLV), uplift modeling, thử nghiệm A/B.

Tài chính — ngân hàng

Chấm điểm tín dụng và PD/LGD/EAD, cảnh báo sớm nợ xấu, dự báo dòng tiền, kiểm định sức chịu đựng.

Rủi ro & tuân thủ

Phát hiện gian lận, giám sát AML, mô hình rủi ro thị trường và vận hành, kiểm định mô hình.

Vận hành & chuỗi cung ứng

Dự báo nhu cầu, tối ưu tồn kho, lập lịch sản xuất, bảo trì dự đoán.

Định giá & doanh thu

Ước lượng độ co giãn của cầu theo giá, định giá động, tối ưu chương trình khuyến mại.

Nhân sự

Dự báo nghỉ việc, phân tích hiệu suất, hoạch định nhân lực theo kịch bản.

Điểm hội tụ: chấm điểm tín dụng gộp cả bốn cấp độ phân tích, đồng thời bộc lộ rõ đánh đổi giữa độ chính xác dự báo và yêu cầu giải thích được theo quy định giám sát.

5 · PHƯƠNG PHÁP LUẬN

Thống kê và học máy: bổ trợ, không thay thế

Cách tiếp cận thống kê
Mục tiêu: SUY DIỄN

- Hiểu cơ chế, ước lượng tham số, kiểm định giả thuyết
- Giả định chặt chẽ, có kiểm định chẩn đoán
- Đầu ra: hệ số, khoảng tin cậy, mức ý nghĩa
- Mạnh: giải thích được, kiểm soát sai lầm loại I/II
- Rủi ro: bỏ sót phi tuyến, chệch do mô hình sai

Cách tiếp cận học máy
Mục tiêu: DỰ BÁO

- Tối thiểu hoá sai số ngoài mẫu, tối ưu năng lực khái quát
- Giả định lỏng, để dữ liệu quyết định dạng hàm
- Đầu ra: điểm dự báo, xác suất, thứ hạng
- Mạnh: quan hệ phi tuyến, tương tác phức tạp, dữ liệu lớn
- Rủi ro: quá khớp, hộp đen, chệch dữ liệu, khó bảo vệ

Nguyên tắc chọn công cụ: xuất phát từ câu hỏi quản trị, không từ độ thời thượng của thuật toán

"Giảm lãi suất 1% tác động thế nào?" → suy diễn nhân quả **"Khách hàng nào sẽ vỡ nợ tháng tới?"** → dự báo

Xu hướng hội tụ: causal forest & double ML · conformal prediction, hiệu chuẩn xác suất · XAI (SHAP, LIME)

Vòng đời một bài toán phân tích

Hiểu bài toán kinh doanh › Hiểu dữ liệu › Chuẩn bị dữ liệu › Mô hình hoá › Đánh giá › Triển khai & giám sát

Khung tham chiếu CRISP-DM — vòng lặp, không tuyến tính

Ba điểm nghẽn làm thất thoát giá trị

1. **Đóng khung sai bài toán**

   Mô hình đúng cho một câu hỏi sai.

2. **Khoảng cách mô hình — hành động**

   Không có quy trình biến kết quả thành quyết định vận hành.

3. **Không giám sát sau triển khai**

   Trôi dạt dữ liệu (data drift) làm mô hình mất hiệu lực.

Đo vai trò của phân tích bằng kết quả kinh doanh

CHỈ SỐ KỸ THUẬT

AUC · RMSE · Precision / Recall

CHỈ SỐ KINH DOANH

Tỷ lệ nợ xấu giảm · chi phí tồn kho tiết kiệm · doanh thu tăng thêm · chi phí thu hút khách hàng giảm

Cầu nối: ma trận chi phí — lợi ích của quyết định. Một mô hình AUC 0,95 vẫn có thể gây lỗ nếu ngưỡng cắt không tối ưu theo chi phí chặn nhầm giao dịch hợp lệ.

Điều kiện cần

- Quản trị dữ liệu: đầy đủ, nhất quán, truy vết được
- Hạ tầng và quy trình MLOps để triển khai, giám sát
- Nhân lực "song ngữ": hiểu cả nghiệp vụ lẫn phương pháp
- Văn hoá chấp nhận bằng chứng phản bác trực giác lãnh đạo

Rào cản thường gặp

- Dữ liệu phân mảnh theo silo giữa các bộ phận
- Kỳ vọng phi thực tế về năng lực của AI
- Thiếu người "dịch" giữa bộ phận phân tích và kinh doanh
- Thiên lệch thuật toán, quyền riêng tư, yêu cầu giải thích được

**Phân tích kinh doanh không thay thế phán đoán của nhà quản lý —
nó nâng cấp chất lượng phán đoán đó bằng bằng chứng định lượng có kiểm soát độ không chắc chắn.**

Câu hỏi mở cho phần sau: nếu giá trị rõ ràng như vậy, vì sao phần lớn dự án phân tích ở doanh nghiệp không đi đến triển khai?

📌 1. Bán lẻ: Dự đoán hành vi khách hàng

- **Tình huống**: Một chuỗi siêu thị như BigC, Vinmart muốn biết loại sản phẩm nào bán chạy theo từng mùa.
- **Ứng dụng phân tích**:
  - Sử dụng **dữ liệu lịch sử giao dịch** để xác định xu hướng tiêu dùng.
  - Dùng mô hình **dự báo doanh số** để quyết định nhập hàng.
- **Lợi ích**: Giảm tồn kho, tăng doanh thu, đưa ra chương trình khuyến mãi đúng thời điểm.

📌 2. Thương mại điện tử: Gợi ý sản phẩm (Recommender System)

- **Tình huống**: Shopee/Lazada muốn giữ chân khách hàng và tăng doanh thu.
- **Ứng dụng phân tích**:
  - Phân tích **hành vi click và mua hàng** để đưa ra gợi ý sản phẩm cá nhân hóa.
- **Lợi ích**: Tăng trải nghiệm người dùng, tăng doanh thu từ bán chéo sản phẩm.

3. Ngân hàng: Phân tích rủi ro tín dụng

- **Tình huống**: Ngân hàng cần xác định khả năng vỡ nợ của người vay.
- **Ứng dụng phân tích**:
  - Xây dựng **mô hình chấm điểm tín dụng (credit scoring)** dựa trên dữ liệu lịch sử, thu nhập, lịch sử tín dụng,...
- **Lợi ích**: Giảm thiểu rủi ro nợ xấu, ra quyết định phê duyệt tín dụng chính xác hơn.

4. Sản xuất: Dự báo nhu cầu và tối ưu chuỗi cung ứng

•**Tình huống**: Một công ty sản xuất cần dự báo nhu cầu để lên kế hoạch mua nguyên vật liệu.

•**Ứng dụng phân tích**:

- Phân tích **xu hướng đơn hàng trong quá khứ**, mô hình hóa dự báo nhu cầu.

•**Lợi ích**: Tối ưu tồn kho, tiết kiệm chi phí sản xuất, tránh thiếu hàng.

5. Marketing: Đo lường hiệu quả chiến dịch

•**Tình huống**: Một doanh nghiệp vừa chạy chiến dịch marketing online, cần biết hiệu quả ra sao.

•**Ứng dụng phân tích**:

- Phân tích **tỷ lệ chuyển đổi (conversion rate)**, chi phí quảng cáo, hành vi khách hàng.

•**Lợi ích**: Đánh giá ROI, điều chỉnh chiến lược marketing hợp lý hơn.

6. Vận hành nội bộ: Phân tích hiệu suất nhân viên

•**Tình huống**: Doanh nghiệp muốn đo lường hiệu quả làm việc của các nhóm nhân viên.

•**Ứng dụng phân tích**:

- Sử dụng dashboard hiệu suất, KPI, dữ liệu phản hồi từ khách hàng.

•**Lợi ích**: Ra quyết định thưởng, đào tạo lại hoặc tái cơ cấu tổ chức

2. Khám phá dữ liệu

2.1. Các loại dữ liệu

Phân loại dữ liệu theo bản chất

Dữ liệu định tính (Qualitative Data / Categorical Data)
Là dữ liệu biểu thị **thuộc tính hoặc phân loại**, không phải là số lượng.

- **Dữ liệu định danh (Nominal):** không có thứ tự
  - Ví dụ: Giới tính (Nam/Nữ), Tình trạng hôn nhân (Độc thân, Kết hôn), Màu sắc (Đỏ, Xanh, Vàng)
- **Dữ liệu thứ bậc (Ordinal):** có thứ tự nhưng không đo được khoảng cách
  - Ví dụ: Mức độ hài lòng (Không hài lòng, Trung bình, Hài lòng, Rất hài lòng), Xếp hạng học lực (Yếu, Trung bình, Khá, Giỏi)

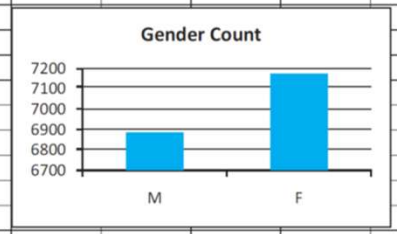
2.2. Khám phá dữ liệu

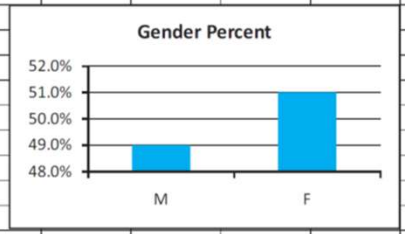
Dữ liệu định lượng (Quantitative Data / Numerical Data)
Là dữ liệu biểu thị **số lượng**, có thể đo lường được.

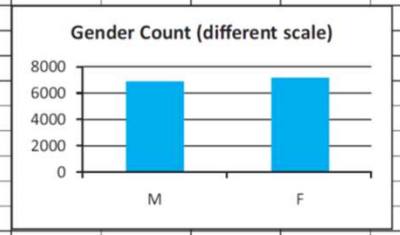
- **Dữ liệu rời rạc (Discrete):** là số nguyên, đếm được
  - Ví dụ: Số con trong gia đình, Số lần mua hàng, Số nhân viên trong công ty
- **Dữ liệu liên tục (Continuous):** là số thực, đo được trên một khoảng
  - Ví dụ: Chiều cao (cm), Cân nặng (kg), Thu nhập (triệu đồng/tháng), Nhiệt độ (°C)

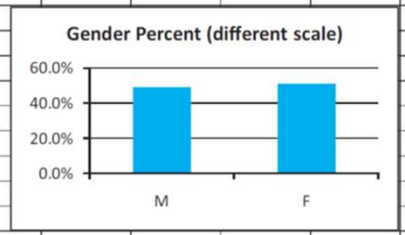
Biến giả (hay còn gọi là **dummy variable**, **biến nhị phân**) là biến được tạo ra để biểu diễn **các biến định tính (categorical variables)** trong mô hình phân tích định lượng, đặc biệt là trong hồi quy tuyến tính, logistic, v.v.
Biến giả chỉ nhận **giá trị 0 hoặc 1**, thể hiện sự **có hoặc không có** của một đặc điểm nào đó.

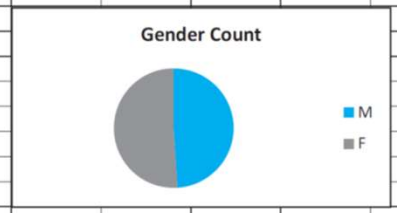
	R	S	T	U
1	**Categorical summaries**			
2	Gender	Count	Percent	
3	M	6889	49.0%	
4	F	7170	51.0%	
5			100.0%	
6				
7	Marital Status	Count	Percent	
8	S	7193	51.2%	
9	M	6866	48.8%	
10			100.0%	
11				
12	Homeowner	Count	Percent	
13	Y	8444	60.1%	
14	N	5615	39.9%	
15			100.0%	
16				
17	Annual Income	Count	Percent	
18	$10K - $30K	3090	22.0%	
19	$30K - $50K	4601	32.7%	
20	$50K - $70K	2370	16.9%	
21	$70K - $90K	1709	12.2%	
22	$90K - $110K	613	4.4%	
23	$110K - $130K	643	4.6%	
24	$130K - $150K	760	5.4%	
25	$150K +	273	1.9%	
26			100.0%	
27				
28				
29				
30				

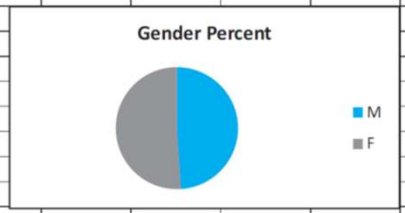












© Cengage Learning

	A	B	C	D	E
1	**Transaction**	**Purchase Date**	**Customer ID**	**Gender**	**Gender Dummy for M**
2	1	12/18/2011	7223	F	0
3	2	12/20/2011	7841	M	1
4	3	12/21/2011	8374	F	0
5	4	12/21/2011	9619	M	1
6	5	12/22/2011	1900	F	0
7	6	12/22/2011	6696	F	0
8	7	12/23/2011	9673	M	1
9	8	12/25/2011	354	F	0
10	9	12/25/2011	1293	M	1
11	10	12/25/2011	7938	M	1
14055	14054	12/29/2013	2032	F	0
14056	14055	12/29/2013	9102	F	0
14057	14056	12/29/2013	4822	F	0
14058	14057	12/31/2013	250	M	1
14059	14058	12/31/2013	6153	F	0
14060	14059	12/31/2013	3656	M	1
14061				Count	6889
14062				Percent	49.0%

© Cengage Learning

	A	B	C	D	E	F	G	H	I	J	K	L
1	**Person**	**Age**	**Gender**	**State**	**Children**	**Salary**	**Opinion**					
2	1	Middle-aged	1	Minnesota	1	$65,400	Strongly agree					
3	2	Elderly	0	Texas	2	$62,000	Strongly disagree					
4	3	Middle-aged	1	Ohio	0	**$63,200**	Neutral					
5	4	Middle-aged	1	Florida	2	$52,000	Strongly agree					
6	5	Young	0	California	3	$81,400	Strongly disagree					
7	6	Young	0	New York	3	$46,300	Strongly agree					
8	7	Elderly	0	Minnesota	2	$49,600	Strongly disagree					
9	8	Middle-aged	1	New York	1	$45,900	Strongly agree					
10	9	Middle-aged	1	Texas	3	$47,700	Agree					
11	10	Young	0	Texas	1	$59,900	Agree					
12	11	Middle-aged	1	New York	1	$48,100	Agree					
13	12	Middle-aged	0	Virginia	0	$58,100	Neutral					
14	13	Middle-aged	0	Illinois	2	$56,000	Strongly disagree					
15	14	Middle-aged	0	Virginia	2	$53,400	Strongly disagree					
16	15	Middle-aged	0	New York	2	$39,000	Disagree					
17	16	Middle-aged	1	Michigan	1	$61,500	Disagree					
18	17	Middle-aged	1	Ohio	0	$37,700	Strongly disagree					
19	**18**	Middle-aged	0	Michigan	**2**	$36,700	Agree					
28	27	Young	1	Illinois	3	$45,400	Disagree					
29	**28**	Elderly	1	**Michigan**	**2**	$53,900	Strongly disagree					
30	29	Middle-aged	1	California	1	$44,100	Neutral					
31	30	Middle-aged	0	New York	2	$31,000	Agree					

Note the formulas in columns B, C, and G that generate this recoded data. The formulas in columns B and G are based on the lookup tables below.

Age lookup table (range name AgeLookup)

0	Young
35	Middle-aged
60	Elderly

Opinion lookup table (range name OpinionLookup)

1	Strongly disagree
2	Disagree
3	Neutral
4	Agree
5	Strongly agree

Phân loại dữ liệu theo cấu trúc thời gian và đơn vị phân tích

Dữ liệu chéo (Cross-sectional data)

•Là dữ liệu được **thu thập tại cùng một thời điểm** (hoặc trong cùng một khoảng thời gian ngắn), nhưng trên **nhiều đơn vị khác nhau** (cá nhân, doanh nghiệp, quốc gia...).

📌 **Ví dụ:**

•Thu nhập của 100 hộ gia đình trong năm 2024.

•Doanh thu của 50 doanh nghiệp trong quý I/2025.

➞ Dữ liệu không có yếu tố thời gian thay đổi theo từng đơn vị.

Dữ liệu chuỗi thời gian (Time series data)

•Là dữ liệu được thu thập theo **trình tự thời gian** trên **một đơn vị duy nhất**.

📌 **Ví dụ:**

•GDP của Việt Nam từ năm 2000 đến 2025.

•Giá cổ phiếu của công ty X theo ngày.

➞ Thời gian là yếu tố quan trọng – dùng để phân tích xu hướng, dự báo.

FIGURE 2.1 Dow Jones Index Values Since 2006



3. Dữ liệu bảng (Panel data / Longitudinal data)

•Là sự kết hợp giữa **dữ liệu chéo** và **chuỗi thời gian**: thu thập dữ liệu **trên nhiều đơn vị qua nhiều thời điểm**.

📌 **Ví dụ:**

•Thu nhập của 100 hộ gia đình trong 5 năm (2020–2024).

•Lợi nhuận của 50 doanh nghiệp trong 8 quý liên tiếp.

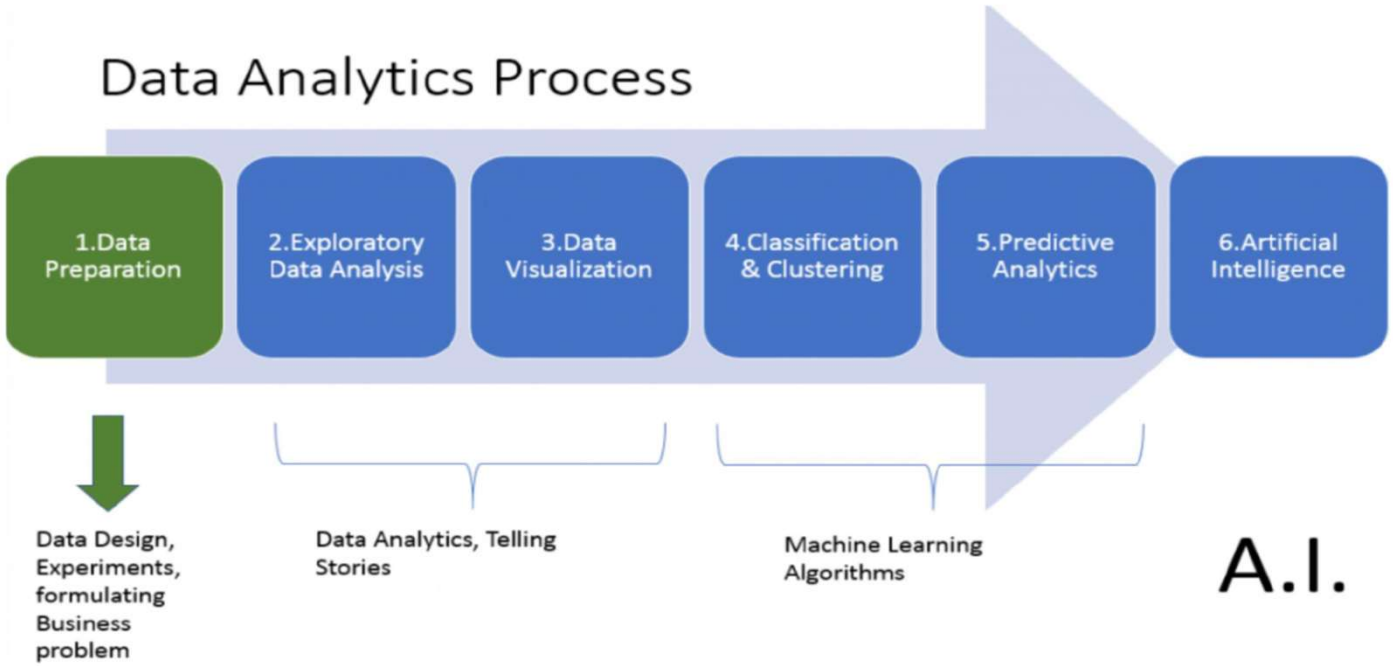
➞ Giúp phân tích **sự thay đổi theo thời gian trong từng đơn vị**, và **khác biệt giữa các đơn vị**.

2.3. Phân tích dữ liệu là gì

Quá trình phân tích dữ liệu thô để đưa ra quyết định

- **Xác định bài toán**
- **Thiết lập các phương pháp đo lường cần thiết và dữ liệu**
- **Thu thập và xử lý dữ liệu**
- **Khám phá và trực quan hóa dữ liệu**
- **Mô hình hóa**
- **Đánh giá mô hình**
- **Phân tích và giải thích**

Data Analytics Process



Làm sạch dữ liệu (data cleaning)	Kiểm tra dữ liệu, làm sạch dữ liệu, loại bỏ các dữ liệu ngoại lai outliers
Chuyển đổi (data transformation)	Biến đổi cấu trúc bộ dữ liệu sang cấu trúc phù hợp để sử dụng trong mô hình
Phân tích (data analysis)	Thực hiện mô hình để trả lời các câu hỏi nghiên cứu

Tổng thể (Population)

Tổng thể là toàn bộ tập hợp các cá thể hoặc đơn vị mà chúng ta quan tâm và muốn nghiên cứu. Ví dụ: tất cả sinh viên trong một trường đại học, tất cả khách hàng của một ngân hàng, hoặc toàn bộ dân cư của một thành phố.

Mẫu (Sample)

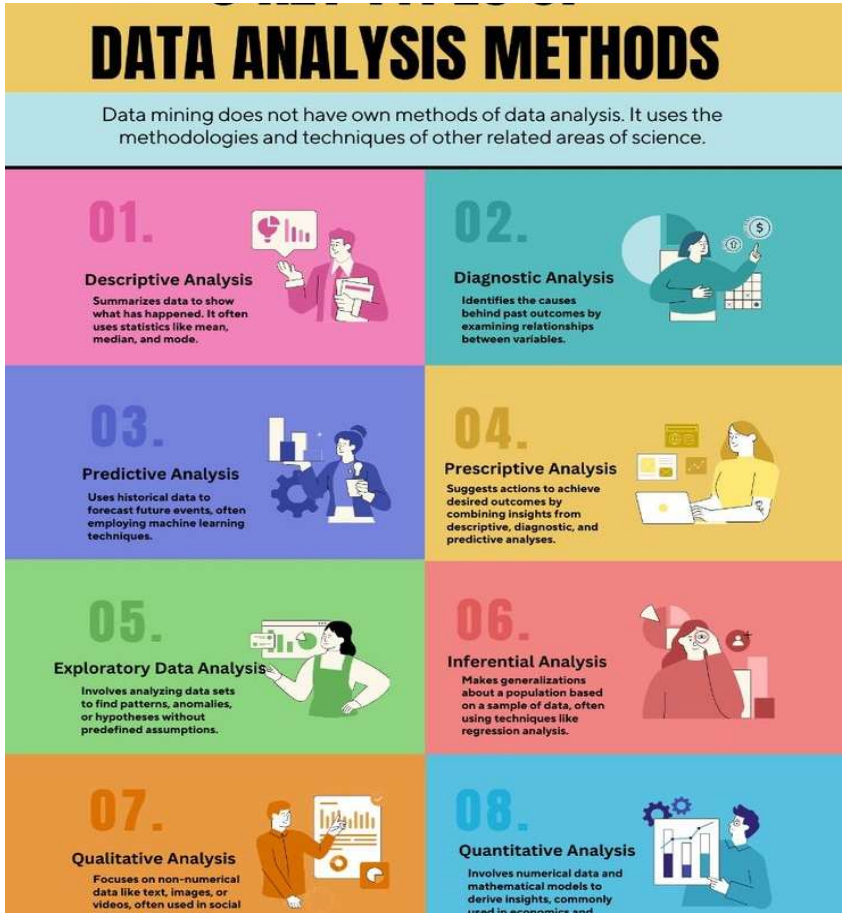
Mẫu là một phần nhỏ được chọn ra từ tổng thể để tiến hành khảo sát hoặc phân tích. Mẫu cần được chọn sao cho đại diện cho tổng thể, từ đó có thể suy luận kết quả cho toàn bộ tổng thể.

Biến (Variable / Field / Attribute)

Biến là một đặc điểm hoặc thuộc tính của các thành viên trong tổng thể. Ví dụ: chiều cao, giới tính, thu nhập, độ tuổi, ngành học, v.v.

Quan sát (Observation / Case / Record)

Quan sát là **toàn bộ giá trị** của các biến đối với **một thành viên cụ thể** trong tổng thể. Ví dụ: thông tin về chiều cao, giới tính và thu nhập của một sinh viên cụ thể.


DATA ANALYSIS METHODS
Data mining does not have own methods of data analysis. It uses the methodologies and techniques of other related areas of science.
01.
Descriptive Analysis
Summarizes data to show what has happened. It often uses statistics like mean, median, and mode.
02.
Diagnostic Analysis
Identifies the causes behind past outcomes by examining relationships between variables.
03.
Predictive Analysis
Uses historical data to forecast future events, often employing machine learning techniques.
04.
Prescriptive Analysis
Suggests actions to achieve desired outcomes by combining insights from descriptive, diagnostic, and predictive analyses.
05.
Exploratory Data Analysis
Involves analyzing data sets to find patterns, anomalies, or hypotheses without predefined assumptions.
06.
Inferential Analysis
Makes generalizations about a population based on a sample of data, often using techniques like regression analysis.
07.
Qualitative Analysis
Focuses on non-numerical data like text, images, or videos, often used in social
08.
Quantitative Analysis
Involves numerical data and mathematical models to derive insights, commonly

1. Bài toán mô tả (Descriptive Analysis)

✅ Mục tiêu: Tóm tắt và mô tả dữ liệu hiện có.

📌 Ví dụ: Doanh số trung bình theo tháng/quý. Tỉ lệ khách hàng theo giới tính, độ tuổi.

🛠️ Công cụ: Thống kê mô tả, bảng tần suất, biểu đồ, dashboard.

2. Bài toán chuẩn đoán (Diagnostic Analysis)

✅ Mục tiêu: Tìm hiểu nguyên nhân hoặc mối quan hệ giữa các yếu tố.

📌 Ví dụ: Vì sao doanh thu giảm vào tháng 9? Khách hàng rời bỏ (churn) do yếu tố nào?

🛠️ Công cụ: Phân tích hồi quy, phân tích tương quan, kiểm định thống kê.

3. Bài toán dự đoán (Predictive Analysis)

✅ Mục tiêu: Dự đoán giá trị tương lai dựa trên dữ liệu quá khứ.

📌 Ví dụ: Dự đoán doanh thu tháng tới. Dự đoán khách hàng có mua hay không.

🛠️ Công cụ: Hồi quy, cây quyết định, random forest, mô hình học máy (machine learning), mạng nơ-ron.

4. Bài toán phân loại (Classification)

✅ Mục tiêu: Phân loại đối tượng vào các nhóm/nhãn rời rạc.

📌 Ví dụ: hân loại email là spam/không spam. Phân loại khách hàng có rủi ro tín dụng cao/thấp.

🛠️ Công cụ: Logistic regression, SVM, k-NN, Random Forest, XGBoost...

🔹 5. Bài toán hồi quy (Regression)

✅ Mục tiêu: Dự đoán giá trị liên tục.

📌 Ví dụ: Dự báo giá nhà, doanh thu, chi phí quảng cáo. 🛠️ Công cụ: Linear regression, Ridge, Lasso, Gradient Boosting...

🔹 6. Bài toán phân cụm (Clustering)

✅ Mục tiêu: Nhóm các đối tượng tương tự nhau mà không có nhãn sẵn.

📌 Ví dụ: Phân khúc khách hàng theo hành vi Nhóm sản phẩm theo đặc điểm mua sắm.

🛠️ Công cụ: K-means, DBSCAN, Hierarchical Clustering.

7. Phân tích định tính (Qualitative Ana7.ysis)

🎯 Mục tiêu:

Khám phá, hiểu sâu và diễn giải hành vi, quan điểm, cảm xúc, và lý do đằng sau các hành động của con người.

Tập trung vào chất lượng và nội dung, chứ không phải số lượng.

📘 Ví dụ bài toán:

Vì sao khách hàng không hài lòng với dịch vụ chăm sóc? Phân tích chủ đề phổ biến trong bình luận mạng xã hội về một thương hiệu. Hiểu cách người dùng sử dụng và trải nghiệm ứng dụng ngân hàng số.

🛠️ Công cụ & phương pháp thường dùng:

Phương pháp: Phỏng vấn sâu (In-depth Interview), Thảo luận nhóm (Focus Group), Phân tích nội dung (Content Analysis), Phân tích chủ đề (Thematic Analysis).

Công cụ: SPSS, R

8. Phân tích định lượng (Quantitative Analysis)

🎯 Mục tiêu: Đo lường, kiểm định giả thuyết, tìm mối quan hệ, dự đoán xu hướng dựa trên dữ liệu số lượng lớn.

Trả lời câu hỏi: Bao nhiêu? Tần suất? Mức độ? Tác động ra sao?

📘 Ví dụ bài toán: Dự đoán xác suất khách hàng rời bỏ dịch vụ (churn prediction). Phân tích các yếu tố ảnh hưởng đến lợi nhuận của doanh nghiệp. Dự báo nhu cầu tiêu thụ điện theo thời gian.

🛠️ Công cụ & phương pháp thường dùng:

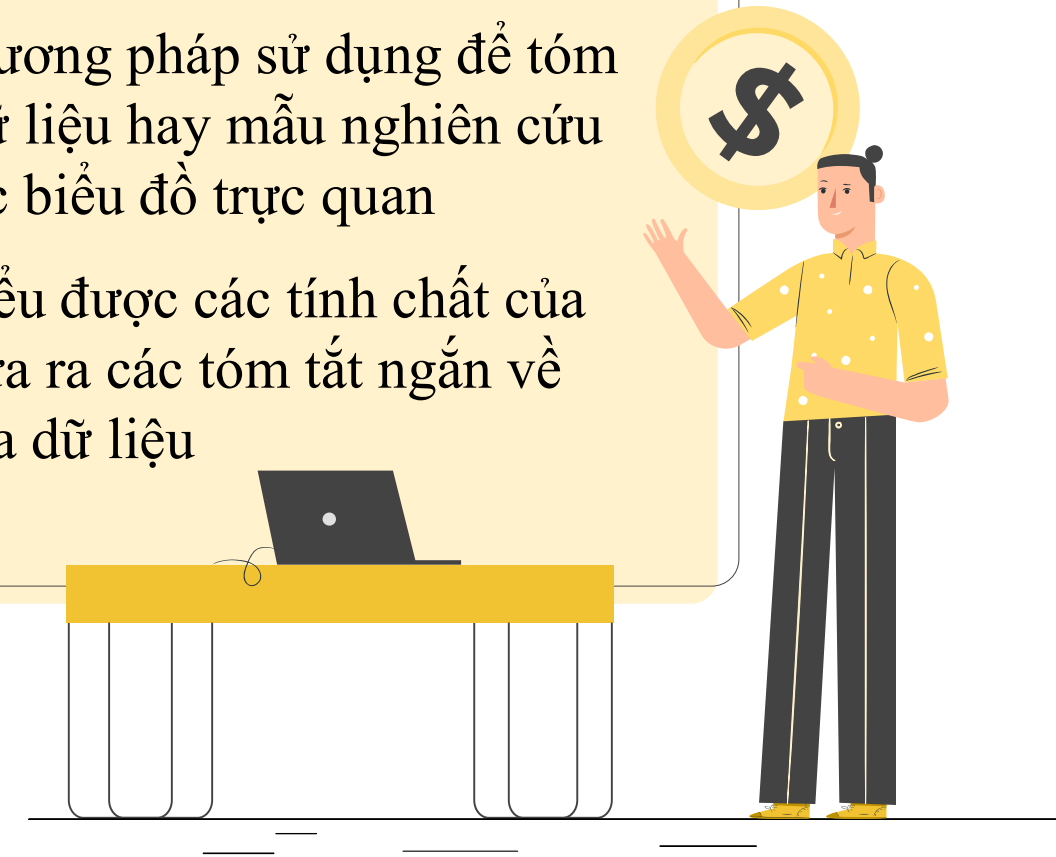
Phương pháp: Thống kê mô tả, Hồi quy tuyến tính/logistic, Kiểm định T, ANOVA, Machine Learning.

Công cụ: Python (pandas, sklearn, statsmodels), R, SPSS, Stata, Excel, Power BI, Tableau.

THỐNG KÊ MÔ TẢ

Thống kê mô tả là các phương pháp sử dụng để tóm tắt hoặc mô tả tập hợp dữ liệu hay mẫu nghiên cứu dưới dạng số hoặc biểu đồ trực quan

Thống kê mô tả giúp hiểu được các tính chất của bộ dữ liệu bằng cách đưa ra các tóm tắt ngắn về mẫu và các thông số của dữ liệu



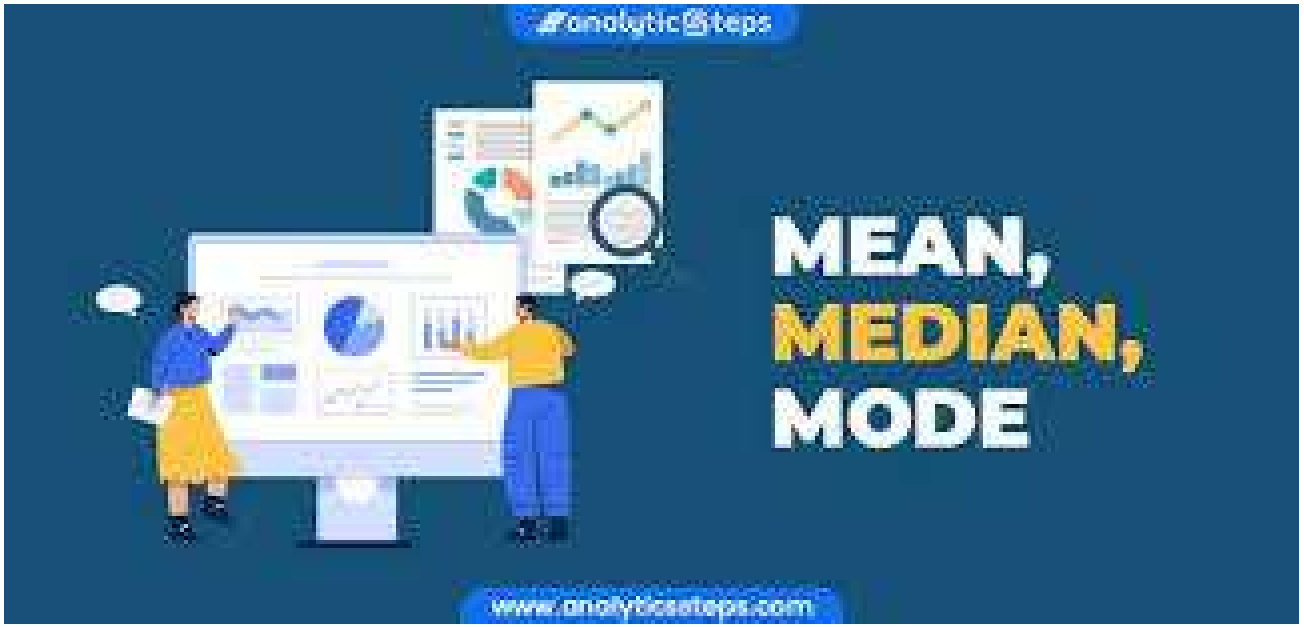
Các đại lượng thường dùng

1. Các đại lượng về trung tâm

2. Các đại lượng về độ phân tán

3. Đo lường sự tương quan

Bảng thống kê mô tả thường đặt ở chương phương pháp nghiên cứu, sau phần giới thiệu dữ liệu nghiên cứu.



Các đại lượng về giá trị trung tâm

Nhằm biểu diễn giá trị thể hiện vị trí/ xu thế trung tâm của tập dữ liệu

- Giá trị trung bình (mean): chỉ giá trị trung tâm

$$\text{Mean} = \frac{\sum_{i=1}^{n} X_i}{n}$$

- Giá trị trung vị (median): trung tâm về vị trí

- Giá trị mode: mức độ tập trung dữ liệu

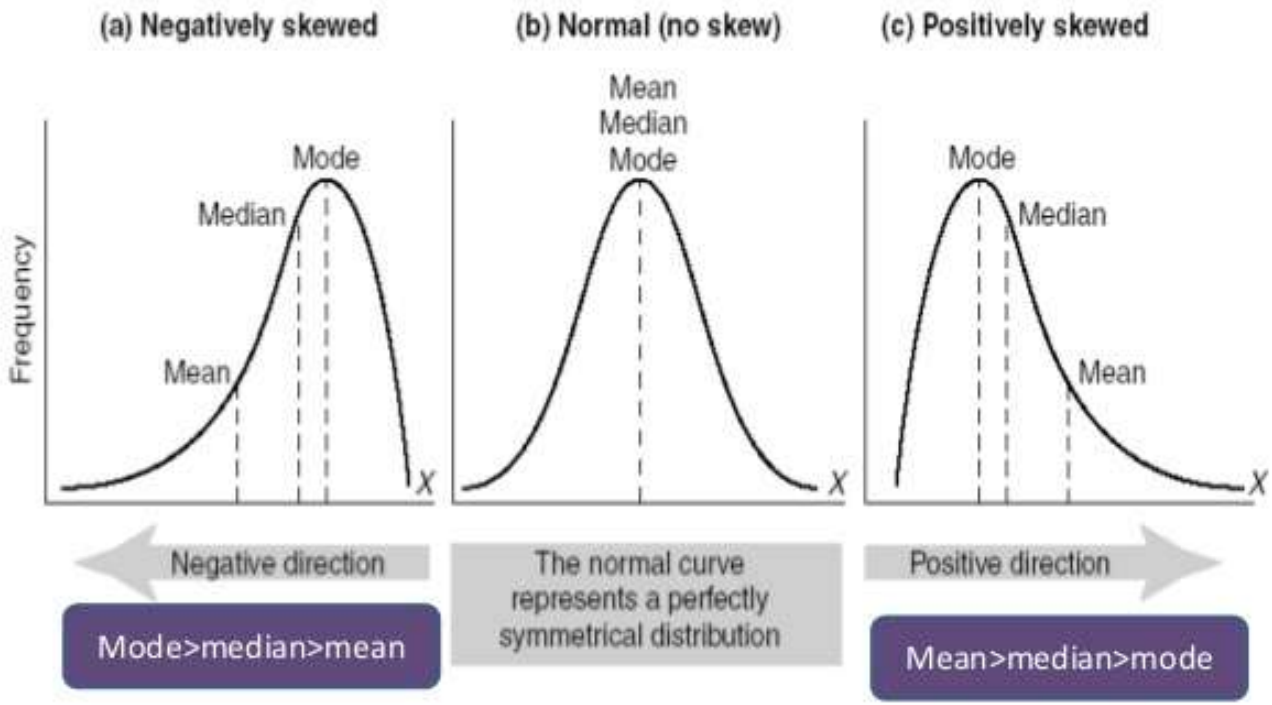
Mode là đại lượng thống kê duy nhất có thể dung cho dữ liệu định tính, mode không bị ảnh hưởng bởi các giá trị đột biến (outliers)

Tứ phân vị (quartiles) là các giá trị chia một tập dữ liệu đã được sắp xếp thành **4 phần bằng nhau**, mỗi phần chiếm 25% số quan sát.

Bách phân vị (percentiles) là các giá trị chia tập dữ liệu thành **100 phần bằng nhau**, mỗi phần chiếm 1% số quan sát.

Quartiles là **trường hợp đặc biệt** của percentiles:
•Q1 = P25
•Q2 = P50
•Q3 = P75

Position of mean median mode



Ví dụ: Dựa vào số liệu customer, hãy tính các giá trị thống kê và phân tích

- **Trung bình, trung vị, min, max các trường dạng số:**
  - Tuổi (Customer_Age)
  - Số người phụ thuộc (Dependent_Count)
  - Thu nhập (Income)
  - Tổng số giao dịch (Total_Trans_Ct)
- **Phân bố điểm hài lòng khách hàng**
- **Tỷ lệ % khách hàng có/không có ô tô, nhà, vay cá nhân,...**

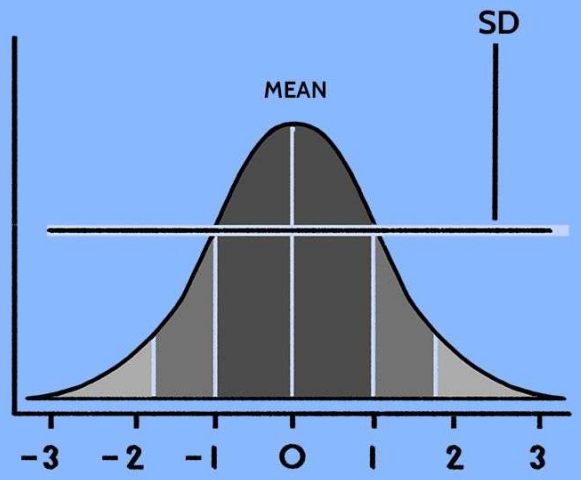
Các đại lượng về độ phân tán

Các đại lượng này sẽ giúp ích trong việc đo lường mức độ biến thiên, mức độ phân tán và dàn trải của dữ liệu. Qua đó, có thể rút ra các nhận xét, mô tả bộ dữ liệu nghiên cứu đầy đủ và chính xác hơn.



Các đại lượng hay sử dụng:

- Khoảng biến thiên, giá trị lớn nhất, nhỏ nhất
- Độ lệch chuẩn **(Standard deviation)** là thước đo độ phân tán của các giá trị trong một tập dữ liệu đã cho từ giá trị trung bình của chúng. Nó cho biết trung bình mỗi giá trị nằm bao xa so với giá trị trung bình.



Standard Deviation

['stan-dərd dē-vē-'ā-shən]

A statistic that measures the dispersion of a dataset relative to its mean and is calculated as the square root of the variance.

Investopedia

1. **Khách hàng trẻ nhất bao nhiêu tuổi?**
   - (Min của Customer_Age)
2. **Thu nhập thấp nhất là bao nhiêu?**
   - (Min của Income)
3. **Khách hàng có ít người phụ thuộc nhất là bao nhiêu?**
   - (Min của Dependent_Count)
4. **Khách hàng nào có tổng số giao dịch thấp nhất?**
   - (Min của Total_Trans_Ct)
5. **Mã số khách hàng nhỏ nhất là bao nhiêu?**
   - (Min của Client_Num)

Các câu hỏi mẫu về độ lệch chuẩn (std):

1. **Độ lệch chuẩn của tuổi khách hàng là bao nhiêu?**
2. **Độ lệch chuẩn của thu nhập khách hàng là bao nhiêu?**
3. **Độ lệch chuẩn của tổng số người phụ thuộc?**
4. **Độ lệch chuẩn của tổng số giao dịch?**
5. **Độ lệch chuẩn điểm hài lòng khách hàng (Cust_Satisfaction_Score)?**

Các đại lượng đo sự tương quan

Đo lường mối quan hệ và sự phụ thuộc giữa hai biến, chỉ ra độ mạnh và xu hướng của mối quan hệ tuyến tính giữa hai biến



Trong quá trình phân tích thống kê, khi muốn xác định mối quan hệ giữa hai biến ngẫu nhiên, chẳng hạn như xác định mức độ tương quan giữa giá dầu thô và giá cổ phiếu của một công ty, cần xác đinh sự tương quan của các biến.

- Hiệp phương sai (Covariance)
- Hệ số tương quan Pearson (Pearson Correlation).

Nếu các biến độc lập có tương quan chặt thì cần xem xét đến vấn đề đa cộng tuyến khi phân tích hồi quy.

Mối quan hệ giữa hai biến thông qua hệ số tương quan:

- 0 đến 0.1: không có quan hệ
- 0.1 đến 0.39: tương quan yếu
- 0.4 đến 0.69: có tương quan vừa
- Lớn hơn 0.7: tương quan mạnh

	PV	DY	PR	SIZE	LD	GA	EV
PV	1						
DY	-0.0237*	1					
PR	-0.0708*	0.2933*	1				
SIZE	-0.0172*	-0.331*	0.0758*	1			
LD	-0.006	-0.0354*	-0.0546*	0.1199*	1		
GA	0.0195*	-0.1067*	-0.0403*	0.0842*	0.0299*	1	
EV	0.1029*	0.1235*	-0.1221*	-0.1406*	-0056	0.0555*	1

Correlation coefficients are reported as follows: PV is the price volatility X(201x). DY and PR are proxies for dividend policy. SIZE is the market value.
LD is long-term debt. GA is the growth in assets. *,**,*** are significant level at 10%, 5%, 1% respectively.

Các câu hỏi về hệ số tương quan

1. **Có mối liên hệ nào giữa tuổi khách hàng (Customer_Age) và thu nhập (Income)?**
2. **Thu nhập (Income) và tổng số giao dịch (Total_Trans_Ct) có tương quan với nhau không?**
3. **Số người phụ thuộc (Dependent_Count) có ảnh hưởng đến thu nhập của khách hàng không?**
4. **Điểm hài lòng khách hàng (Cust_Satisfaction_Score) và tổng số giao dịch (Total_Trans_Ct) có mối quan hệ như thế nào?**
5. **Có sự liên hệ giữa số người phụ thuộc và điểm hài lòng khách hàng không?**
6. **Mối quan hệ giữa tuổi khách hàng và tổng số giao dịch thực hiện là gì?**
7. **Thu nhập có liên quan đến điểm hài lòng khách hàng không?**
8. **Tổng số giao dịch có tương quan với số người phụ thuộc không?**
9. **Các biến số lượng (số) trong bộ dữ liệu này có phụ thuộc/tác động lẫn nhau như thế nào (quan sát trên heatmap)?**

📊 Biểu đồ hộp (Box Plot) là gì?

Box Plot (hay còn gọi là **box-and-whisker plot**) là một loại biểu đồ thống kê dùng để:

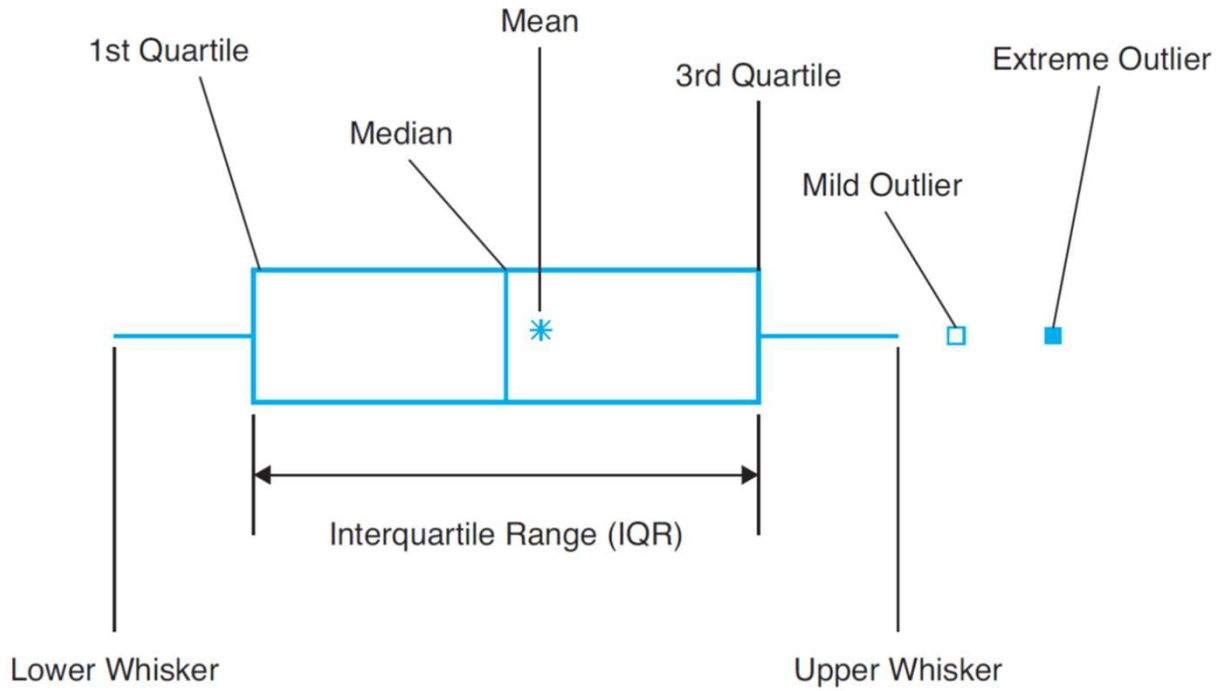
- 🔹 **Tóm tắt sự phân phối của dữ liệu** thông qua các thước đo vị trí như:

- **Tứ phân vị thứ nhất (Q1)**
- **Trung vị (Q2 / Median)**
- **Tứ phân vị thứ ba (Q3)**
- **Giá trị nhỏ nhất (Min)** và **giá trị lớn nhất (Max)** (không tính ngoại lai)

- 🔹 **Xác định các giá trị ngoại lai (outliers)** một cách trực quan

📌 Ý nghĩa sử dụng

✅ So sánh phân phối giữa các nhóm
✅ Phát hiện sự **lệch** (skewness) hoặc **ngoại lai** (outlier)
✅ Đơn giản hóa tập dữ liệu lớn trong trực quan hóa



Whiskers extend to the furthest observations that are no more than 1.5 IQR from the edges of the box. Mild outliers are observations between 1.5 IQR and 3 IQR from the edges of the box. Extreme outliers are greater than 3 IQR from the edges of the box.

© Cengage Learning

📊 Histogram là gì?

Histogram (biểu đồ tần số) là một loại biểu đồ cột dùng để:

✅ **Trực quan hóa phân phối của dữ liệu định lượng**

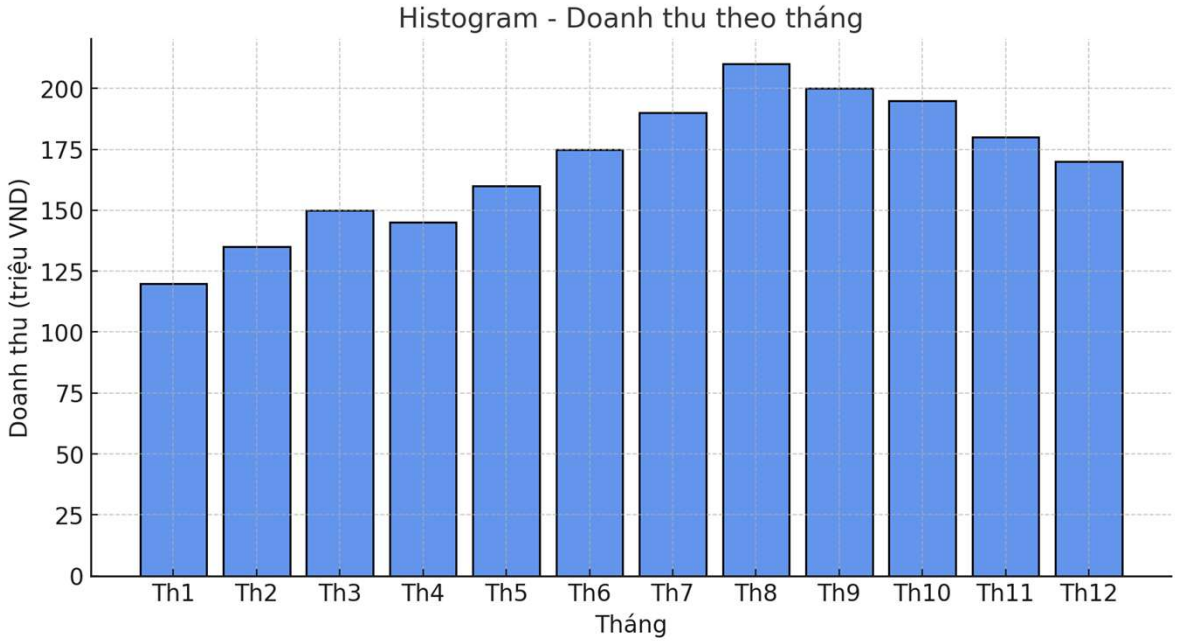
✅ Cho thấy **tần suất xuất hiện** của các giá trị trong các khoảng (bins)

🔍 Đặc điểm của Histogram

- **Trục hoành (x-axis):** chia thành các **khoảng giá trị (bins)** không trùng lặp
- **Trục tung (y-axis):** biểu thị **tần suất** (số lượng) hoặc **tần suất tương đối** của các giá trị trong mỗi khoảng
- **Các cột liền nhau** (khác với biểu đồ cột thường – column chart – có khoảng cách giữa các cột)

✅ Mục đích sử dụng

- Xem **hình dạng phân phối** dữ liệu (chuông, lệch trái, lệch phải, đồng đều…)
- Phát hiện sự bất thường, phân nhóm hoặc độ phân tán của dữ liệu


Histogram - Doanh thu theo tháng
Doanh thu (triệu VND)
0
25
50
75
100
125
150
175
200
Th1
Th2
Th3
Th4
Th5
Th6
Th7
Th8
Th9
Th10
Th11
Th12
Tháng

Data visualization là quá trình chuyển đổi dữ liệu thành các biểu đồ trực quan nhằm cung cấp thông tin dễ hiểu, chính xác đến người đọc

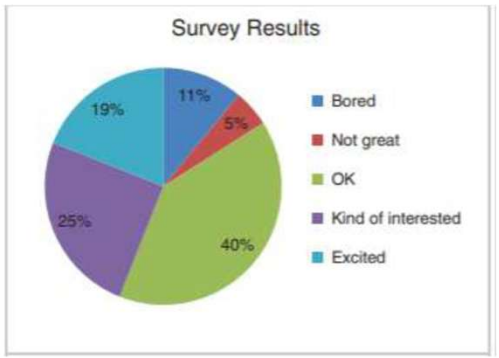
Quy trình trực quan hóa dữ liệu

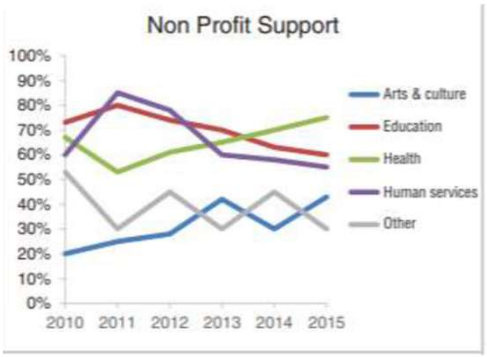
1. Hiểu bối cảnh, mục tiêu thông tin truyền tải
2. Lựa chọn biểu đồ phù hợp
3. Loại bỏ các yếu tố gây nhiễu
4. Trích xuất các thông tin quan trọng cần truyền tải
5. Hoàn thiện thiết kế
6. Vẽ dashboard kể câu chuyện

1. Hiểu bối cảnh:

- Đối tượng đọc, ra quyết định (quản lý, khách khàng,…): họ muốn biết thông tin gì
- Nhà quản lý cao cấp: thông tin về xu hướng, nhu cầu xây dựng kế hoạch dài hạn để ra quyết định chiến lược
- Nhà quản lý cấp trung: thông tin trung ngắn hạn về doanh thu sản phẩm, khách hàng, chiến dịch,…
- Nhà quản lý cấp cơ sở: Dữ liệu đơn vị, nhân viên, kết quả công việc và xử lý vấn đề phát sinh

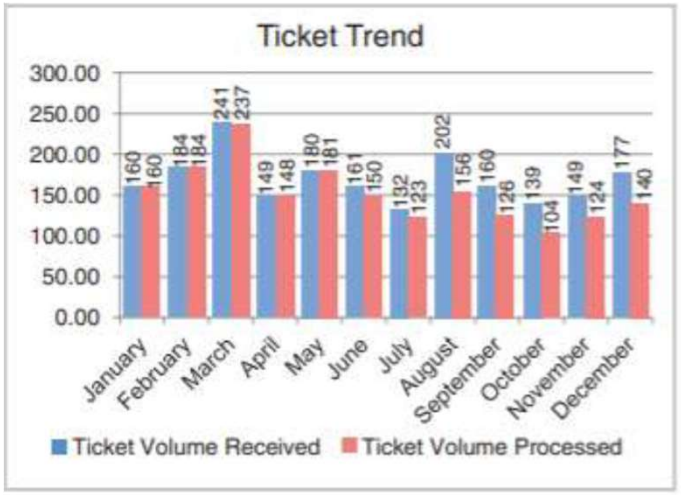
2. Lựa chọn biểu đồ phù hợp

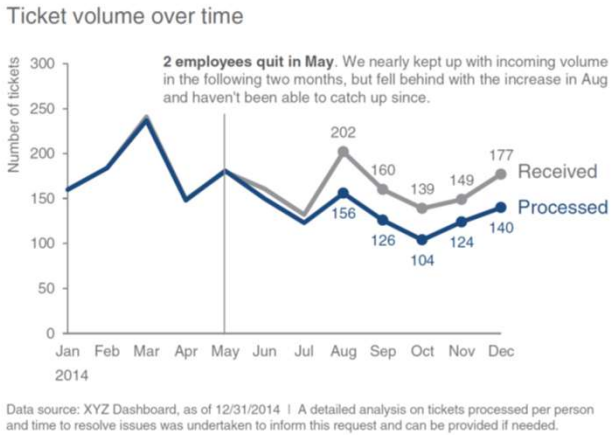




Hãy xác định rõ ràng mục đích và câu hỏi của báo cáo

2. Lựa chọn biểu đồ phù hợp



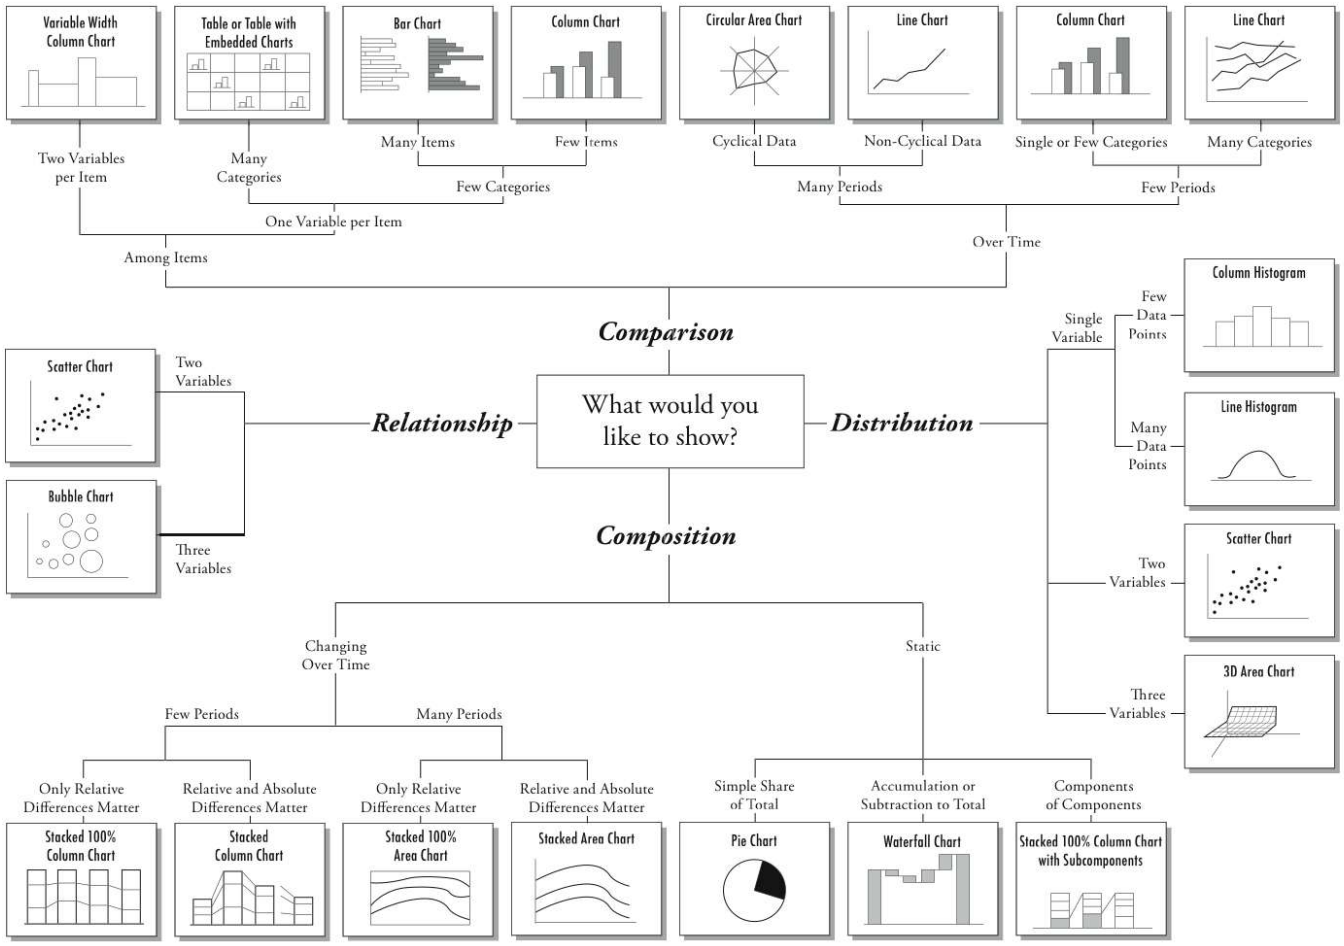


So sánh số người quit trước và sau khi showing dữ liệu

- **So sánh (comparison):** bar chart, column chart, heatmap
- **Phân phối (distribution):** histogram
- **Xu hướng (trend):** line chart
- **Tương quan (relationship):** scatter plot

Thành phần (composition): pie chart, stacked bar chart

Chart Suggestions—A Thought-Starter



www.ExtremePresentation.com
© 2009 A. Abela — a.v.abela@gmail.com

CÁC DẠNG BIỂU ĐỒ

XU HƯỚNG THEO THỜI GIAN



Line

Các cột làm việc tốt cho việc hiển thị thay đổi theo thời gian – nhưng thường tốt nhất chỉ với một chuỗi dữ liệu tại một thời điểm



Column

Các cột làm việc tốt cho việc hiển thị thay đổi theo thời gian nhưng thường tốt nhất chỉ với một chuỗi dữ liệu tại một thời điểm



Column + line timeline

Một cách tốt để hiển thị mối quan hệ theo thời gian giữa số lượng (cột) và tỷ lệ (đường)



Slope

Tốt cho việc hiển thị dữ liệu thay đổi miễn là dữ liệu có thể đươợc đơn giản hóa thành 2 hoặc 3 điểm mà không bỏ sót phần quan trọng nào của câu chuyện



Area chart

Sử dụng cẩn thận, những thứ này rất tốt cho việc hiển thị các thay đổi về tổng thể, nhưng để nhìn thay đổi trong các thành phần có thể rất khó khăn.

CƠ CẤU



Stacked column/bar

Một cách đơn giản của việc hiển thị một phần đến toàn bộ mối quan hệ nhưng có thể khó để đọc với nhiều hơn một vài thành phần



Pie

Một cách phổ biến để hiển thị một phần đến toàn bộ dữ liệu nhưng lưu ý rằng nó rất khó để so sánh chính xác kích thước của các phân đoạn



Donut

Tương tự như một biểu đồ bánh nhưng ở trung tâm có thể là một cách tốt tạo khoảng trống để bao gồm thêm thông tin về dữ liệu
(ví dụ: tổng số)



Treemap

Sử dụng cho mối quan hệ từ thành phần đến tổn g thể phân cấp, có thể khó để đọc khi có nhiềup hân đoạn nhỏ



Waterfall

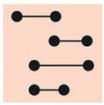
Có thể hữu ích cho việc hiển thị mối quan hệ từ thành phần đến tổng thể, trong đó một số th ành phần là tiêu cực

PHÂN PHỐI



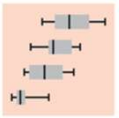
Histogram

Cách tiêu chuẩn để hiển thị một số liệu thống kê phân phối-
giữ những khoảng cách trống nhỏ giữa các cột để làm nổi bật "hình dạng" của dữ liệu.



Dot plot

Cách đơn giản của việc hiển thị thay đổi hoặc phạm vi (nhỏ nhất/lớn nhất) của dữ liệu sang danh mục



Boxplot

Tổng hợp nhiều phân phối bằng hiển thị trung vị (trung tâm) và phạm vi của dữ liệu.



Violin plot

Tương tự như biểu đồ hộp nhưng hoàn hảo hơn với các phân phối phức tạp (dữ liệu không thể tóm tắt b ằng trung bình đơn giản)



Population pyramid

Một cách tiêu chuẩn để hiển thị sự cố về độ tuổi và giới tính của một phân phối dân số hiệu quả, quay lại tần suất



Cumulative curve

Một cách tốt để chỉ ra mức độ bất bình đẳng của một phân phối là: trục y luôn là tần suất tích lũy, t rục x luôn là thước đo

CÁC DẠNG BIỂU ĐỒ

MỐI QUAN HỆ



Scatterplot

Cách tiêu chuẩn để hiển thị một chuỗi thờigian thay đổi. Nếu dữ liệu không đều, xem xét đánh dấu để biểu thị các điểm dữ liệu.



Column + line timeline

Một cách tốt để hiển thị mối quan hệ giữa số l ượng (cột) và tỷ lệ (đường)



Connected scatterplot

Thường sử dụng cho việc chỉ ra mối quan hệ giữa hai biến thay đổi theo thời gian



Bubble

Giống như biểu đồ phân tán, nhưng thêm chi tiết bổ sung bằng cách định cỡ các vòng tròn theo biến thứ ba



XY heatmap

Một cách tốt để hiển thị các mẫu giữa 2 danh mục của dữ liệu. Ít hiệu quả trong việc thể hiện sự khác biệt về số lượng

SO SÁNH QUA TRỤC



Diverging bar

Một biểu đồ thanh tiêu chuẩn đơn giản có thể giải quyết cả hai giá trị độ lớn âm và dương



Diverging stacked bar

Hoàn hảo để trình bày kết quả khảo sát liên quan đến cảm xúc (ví dụ: không đồng ý/ trung lập/ đồng ý)



Spine

Tách một giá trị đơn thành hai thành phần tươn g phản (ví dụ: nam/ nữ)



Surplus/deficit filled line

Vùng bóng mờ của các biểu đồ này cho phép sự cân bằng để hiển thị - hoặc là chống lại một dòng cơ sở hoặc giữa hai chuỗi

XẾP HẠNG VÀ SO SÁNH



Ordered bar

Biểu đồ thanh tiêu chuẩn hiển thị thứ hạng của các giá trị dễ dàng hơn khi được xếp theo thứ tự



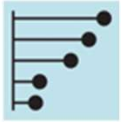
Ordered column

Xem ở trên



Slope

Hoàn hảo cho việc hiển thị thứ hạng đã thay đổi như thế nào theo thời gian hoặc thay đổi giữa các danh mục



Lollipop

Biểu đồ kẹo mút thu hút nhiều hơn sự chú ý đến giá trị dữ liệu so với thanh/cột tiêu chuẩn và có thể hiển thị thứ hạng và giá trị hiệu quả hiệu quả.

Phân tích định tính/phân loại (thống kê tần suất)

- **Biểu đồ tần suất (bar plot) các biến phân loại:**
  - Giới tính (Gender)
  - Trình độ học vấn (Education_Level)
  - Nghề nghiệp (Customer_Job)
  - Hình thức liên hệ (contact)
  - Tình trạng hôn nhân (Marital_Status)

Gợi ý các biểu đồ và trực quan hóa

1. **Histogram** cho các biến: Tuổi, Thu nhập, Tổng số giao dịch.
2. **Boxplot** để so sánh phân bố Thu nhập theo từng trình độ học vấn hoặc giới tính.
3. **Bar chart** cho các biến phân loại: Số lượng khách hàng theo từng trình độ học vấn, nghề nghiệp, tình trạng hôn nhân...
4. **Pie chart** cho tỷ lệ giới tính, tỷ lệ khách có/không có ô tô hoặc nhà.
5. **Heatmap** để xem mối tương quan giữa các biến số (tuổi, thu nhập, số giao dịch, điểm hài lòng...).

1. **Cơ bản về khách hàng**

- Số lượng khách hàng theo **giới tính**? (Biểu đồ Cột hoặc Tròn)
- Phân bố **tuổi khách hàng** như thế nào? (Histogram hoặc Box Plot)
- Khách hàng tập trung nhiều nhất ở những **tỉnh/bang** nào? (Bản đồ hoặc Biểu đồ Cột)
- Tỷ lệ khách hàng theo **tình trạng hôn nhân**?

2. **Thông tin học vấn, nghề nghiệp**

- Số lượng khách hàng theo **trình độ học vấn**?
- Số lượng khách hàng theo **nghề nghiệp**?
- **Trình độ học vấn** có liên hệ gì với thu nhập không? (Boxplot thu nhập theo học vấn)

3. **Thu nhập & giao dịch**

- Phân phối **thu nhập khách hàng**? (Histogram)
- Nhóm khách hàng có **thu nhập cao nhất** là những nhóm nào? (Top N)
- Phân tích **tổng số giao dịch** theo tháng, năm (nếu có trường thời gian)
- Sự khác biệt về **thu nhập giữa các giới tính**?

4. **Sản phẩm, dịch vụ**

- Tỷ lệ khách hàng **sở hữu ô tô/nhà** (Car_Owner, House_Owner)? (Pie Chart)
- Số lượng khách hàng đang có **vay cá nhân (Personal_loan)**?
- Dạng liên hệ (cellular/telephone/unknown) nào được **khách hàng sử dụng nhiều nhất**?

5. **Mối quan hệ giữa các đặc điểm**

- Thu nhập trung bình theo **nghề nghiệp** hoặc **học vấn**? (Bar Chart)
- Số giao dịch trung bình theo **độ tuổi** hoặc **nhóm tuổi**?
- Sự khác biệt về **điểm hài lòng** giữa các nhóm nghề nghiệp, nhóm tuổi?

6. **Khách hàng tiềm năng & phân khúc**

- Top 10 khách hàng có **số giao dịch lớn nhất**.
- Nhóm khách hàng có **điểm hài lòng cao nhất** gồm những ai?
- Tỷ trọng khách hàng theo **phân khúc thu nhập** (vd: thấp, trung bình, cao)?

. **Câu hỏi so sánh/đa chiều**

. Nhóm nào (giới tính, nghề nghiệp…) có tỷ lệ sở hữu ô tô/nhà/vay cá nhân cao hơn?

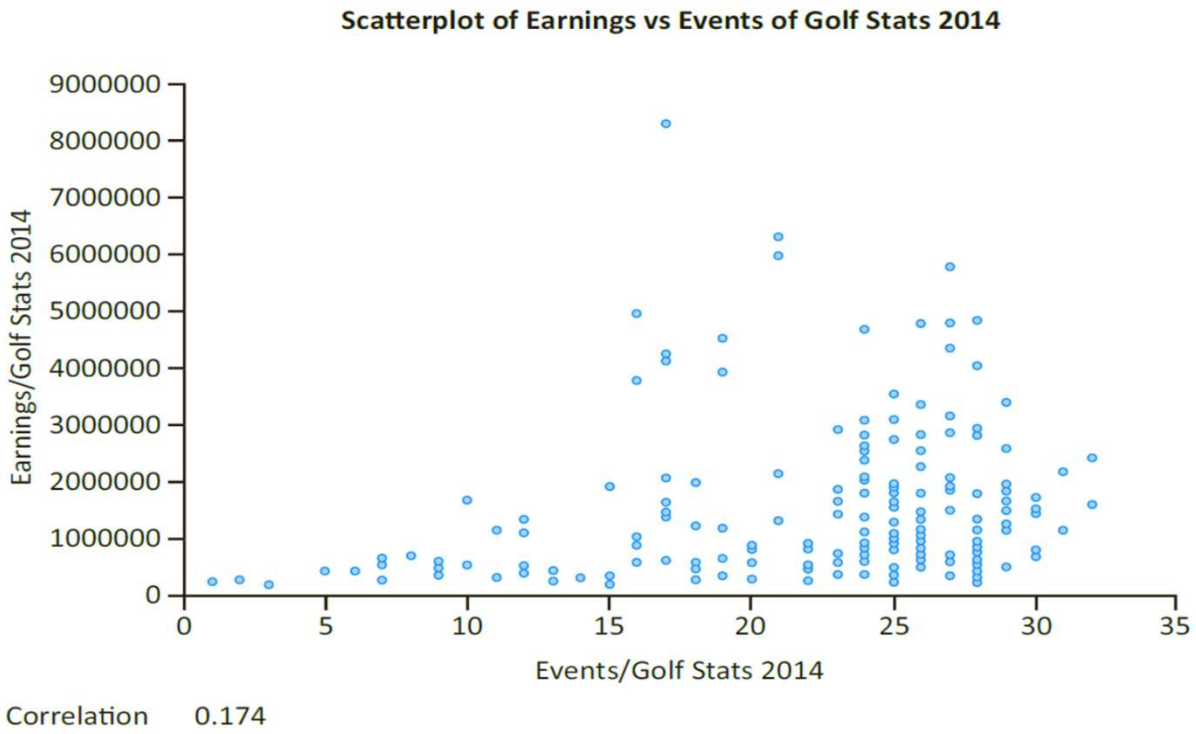
. Điểm hài lòng trung bình giữa các bang/tỉnh có khác biệt gì?

. Số giao dịch và thu nhập có tương quan với nhau không? (Scatter Plot)

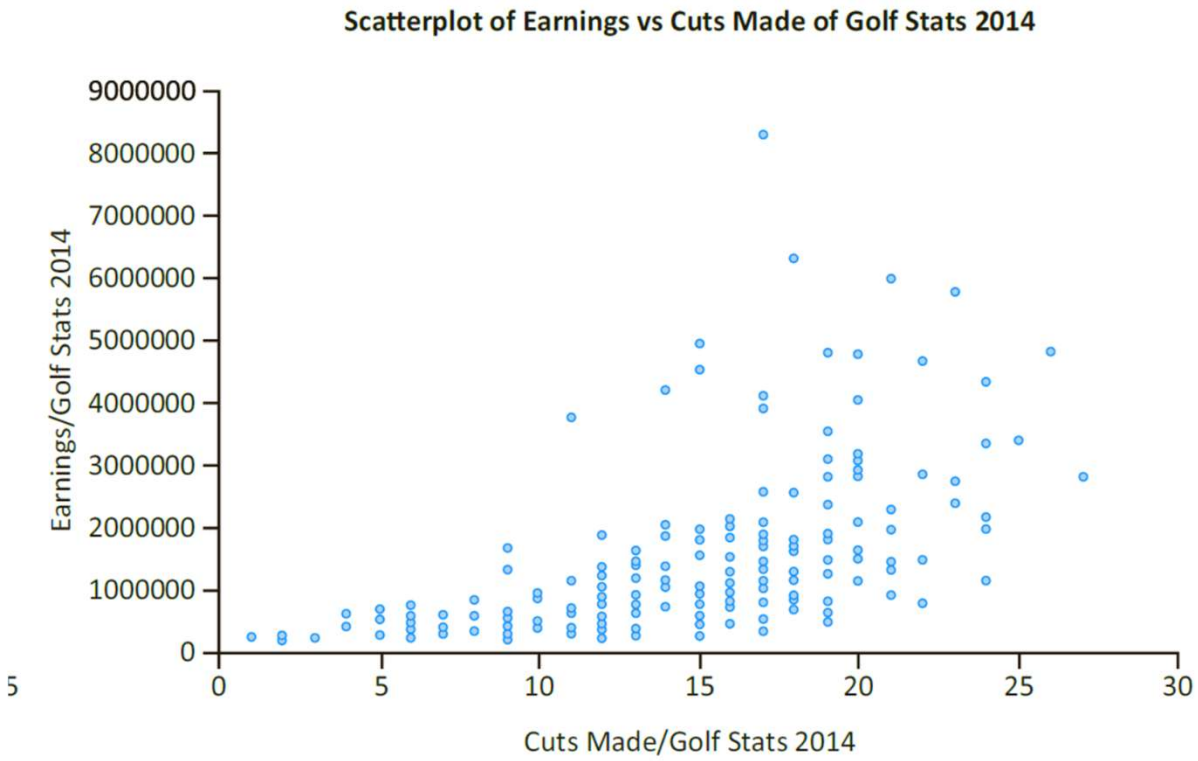
Scatter plot

Scatter plot là một **tập hợp các điểm** trên mặt phẳng tọa độ.
•**Mỗi điểm** trên đồ thị tương ứng với **một quan sát (observation)** trong tập dữ liệu, thể hiện **giá trị đồng thời** của X và Y ở thời điểm hoặc đối tượng đó.

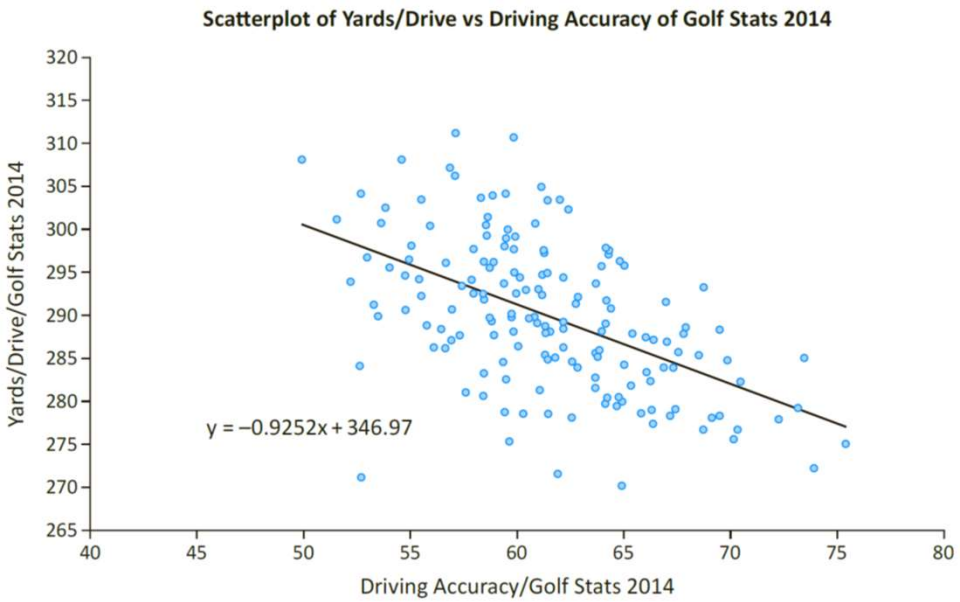
Giúp ta **quan sát trực quan mối quan hệ giữa hai biến số**, cụ thể là:
•**Mối quan hệ tuyến tính dương**: Các điểm có xu hướng đi lên từ trái sang phải → Y tăng khi X tăng.
•**Mối quan hệ tuyến tính âm**: Các điểm có xu hướng đi xuống từ trái sang phải → Y giảm khi X tăng.
•**Mối quan hệ phi tuyến (nonlinear)**: Các điểm tạo thành đường cong hoặc hình dạng đặc biệt (ví dụ: parabol, hình chữ U).
•**Không có mối quan hệ rõ ràng**: Các điểm phân bố ngẫu nhiên, không theo xu hướng nào.
•**Phát hiện điểm ngoại lai (outlier)**: Những điểm nằm xa so với phần lớn các điểm còn lại.



Đồ thị Scatter nhìn không có hình dạng rõ ràng không có mối quan hệ giữa hai đại lượng

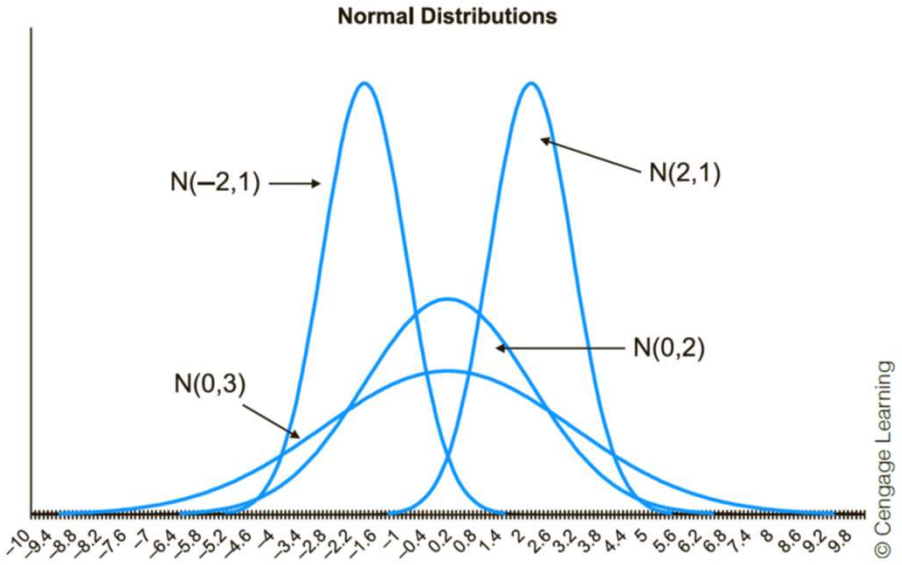


Correlation 0.573



Có mối quan hệ tuyến tính ngược chiều giữa Driving Accuracy và Yards

Phân phối chuẩn:



3. Khai phá dữ liệu và thống kê suy luận

3.1. Khai phá dữ liệu mô tả

Khai phá dữ liệu mô tả (một phương pháp học không giám sát) giúp tìm hiểu cấu trúc, mẫu và mối quan hệ từ dữ liệu lớn mà không dùng mô hình dự đoán. Trong một ứng dụng học không giám sát, không có biến kết quả nào để dự đoán; thay vào đó, mục tiêu là sử dụng các giá trị biến để xác định mối quan hệ giữa các quan sát. Các phương pháp học không giám sát có thể được coi là phân tích mô tả đa chiều vì chúng được thiết kế để mô tả các mẫu và mối quan hệ trong các tập dữ liệu lớn với nhiều quan sát của nhiều biến. Nếu không có kết quả rõ ràng (hoặc kết quả được biết đến một cách khách quan), sẽ không có thước đo chính xác nào

Mục tiêu khai phá dữ liệu mô tả
•Tóm tắt thông tin quan trọng
•Phát hiện mẫu và xu hướng trong dữ liệu
•Hỗ trợ ra quyết định bằng cách hiểu dữ liệu hiện có

Khái niệm phân cụm (Clustering)

•Phân cụm là kỹ thuật khai phá dữ liệu mô tả dùng để nhóm các đối tượng dữ liệu thành các nhóm (cụm) sao cho các đối tượng trong cùng một nhóm có sự tương đồng cao với nhau, đồng thời khác biệt rõ rệt với các nhóm khác.

•Mục đích: Phân tách dữ liệu thành các phân đoạn có tính chất đồng nhất, giúp hiểu rõ cấu trúc dữ liệu, nhận biết mô hình, hoặc phân đoạn khách hàng, sản phẩm...

•Phân cụm là kỹ thuật không giám sát (unsupervised learning), nghĩa là không cần các nhãn hay kết quả đầu ra trước đó.

•**Đo lường sự tương đồng:** Để nhóm các đối tượng, trước tiên cần phải đo lường mức độ tương đồng hoặc khác biệt giữa chúng. Các phương pháp phổ biến bao gồm khoảng cách Euclid và các thước đo khác tùy thuộc vào loại dữ liệu.

•**Phân cụm phân cấp (Hierarchical Clustering):** Phương pháp này xây dựng một hệ thống phân cấp các cụm. Có hai cách tiếp cận chính:

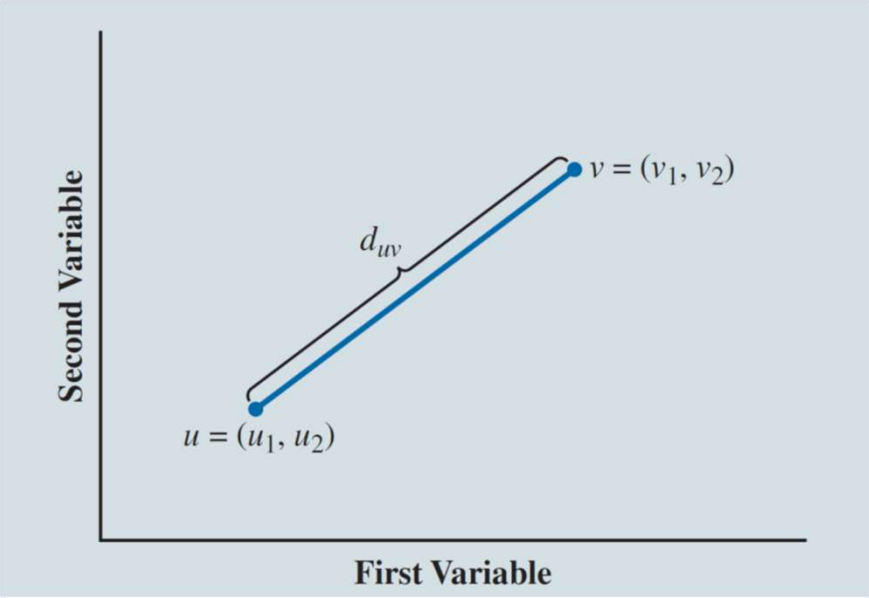
+**Gom cụm (Agglomerative):** Bắt đầu với mỗi đối tượng là một cụm riêng lẻ, sau đó hợp nhất các cụm gần nhất cho đến khi chỉ còn một cụm duy nhất.

+**Chia cụm (Divisive):** Bắt đầu với tất cả các đối tượng trong một cụm duy nhất, sau đó chia nhỏ dần cho đến khi mỗi đối tượng là một cụm riêng.

•**Phân cụm k-Means (k-Means Clustering):** Đây là một phương pháp phổ biến nhằm chia một tập dữ liệu thành *k* cụm đã xác định trước. Thuật toán sẽ gán mỗi đối tượng vào cụm có tâm (centroid) gần nhất.

Mục tiêu của phân tích cụm là nhóm các quan sát thành các cụm sao cho các quan sát trong một cụm là tương tự nhau và các quan sát trong các cụm khác nhau là khác nhau.Để đo sự tương đồng, sử dụng các khoảng cách hoặc hàm đo sự tương đồng

$$d_{uv} = \sqrt{(u_1 - v_1)^2 + (u_2 - v_2)^2 + \cdots + (u_q - v_q)^2}$$



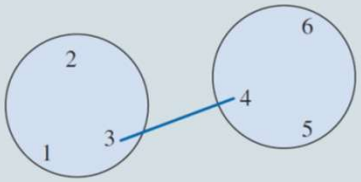
Hierarchical Clustering tạo ra một **cây phân cấp (dendrogram)** để mô tả cách các cụm được hình thành bằng cách hợp nhất hoặc tách dần các điểm dữ liệu.
Có hai cách tiếp cận chính:

- **a. Agglomerative (Phân cụm dồn – Bottom-up)**

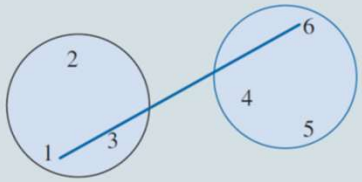
•Là phương pháp **thường dùng nhất**.
•Mỗi điểm dữ liệu bắt đầu là một cụm riêng biệt.
•Ở mỗi bước, hai cụm gần nhau nhất được **gộp lại**.
•Quá trình lặp lại cho đến khi toàn bộ dữ liệu trở thành một cụm duy nhất.

- **b. Divisive (Phân cụm tách – Top-down)**

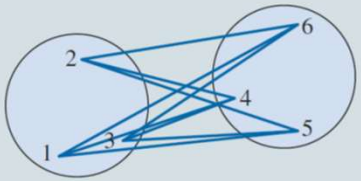
•Bắt đầu từ một cụm lớn chứa tất cả các điểm dữ liệu.
•Sau đó **tách dần** cụm thành các cụm con nhỏ hơn.
•Ít phổ biến hơn do tính toán phức tạp.



Single Linkage, $d_{3,4}$

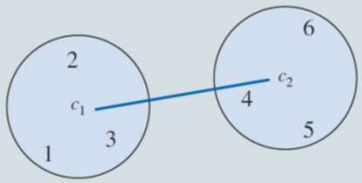


Complete Linkage, $d_{1,6}$



Group Average Linkage,

$$\frac{d_{1,4}+d_{1,5}+d_{1,6}+d_{2,4}+d_{2,5}+d_{2,6}+d_{3,4}+d_{3,5}+d_{3,6}}{9}$$



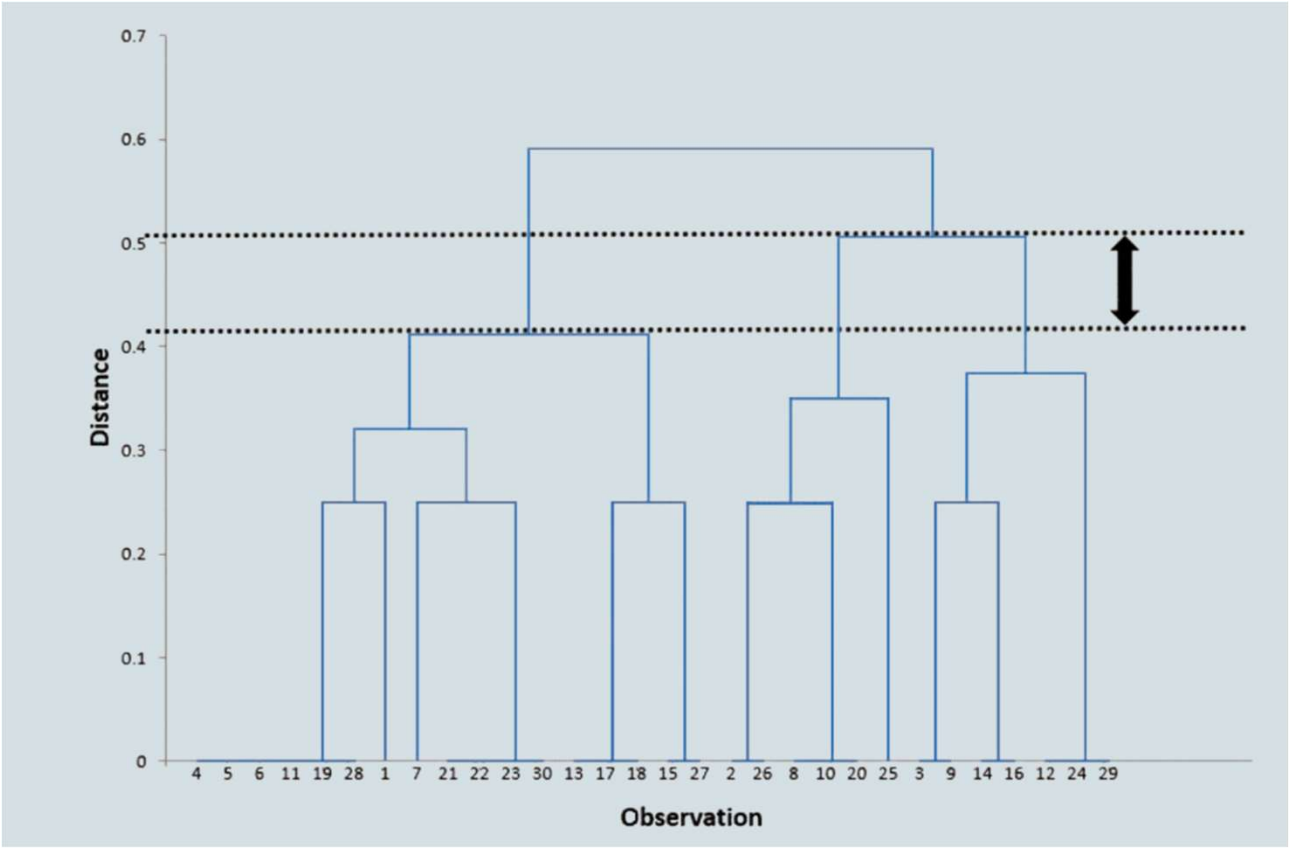
Centroid Linkage, d_{c_1,c_2}

1. Single Linkage (Liên kết đơn)

- **Công thức:**

$$L(R,S) = \min_{i \in R,\, j \in S} D(i,j)$$

- **Giải thích:** Khoảng cách giữa hai cụm được xác định bằng cặp điểm gần nhau nhất.
- **Hệ quả:** Tạo ra các cụm "chain-like" dài và mảnh, do chỉ cần một cặp điểm gần nhau là cụm có thể kết nối.
- **Ứng dụng/nhược điểm:** Rất nhạy với outlier, dễ gây "hiệu ứng chuỗi" GeeksforGeeks +12 .


0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
Distance
4 5 6 11 19 28 1 7 21 22 23 30 13 17 18 15 27 2 26 8 10 20 25 3 9 14 16 12 24 29
Observation

2. Complete Linkage (Liên kết đầy đủ)

- **Công thức:**

$$L(R, S) = \max_{i \in R,\, j \in S} D(i, j)$$

- **Giải thích:** Khoảng cách giữa hai cụm là khoảng cách lớn nhất giữa các điểm của hai cụm.
- **Hệ quả:** Tạo ra các cụm chặt và có hình dạng gần tròn.
- **Ưu điểm:** Giảm thiểu hiệu ứng "chuỗi", cấu trúc ổn định hơn GeeksforGeeks Wikipedia.

3. Average Linkage (Liên kết trung bình)

- **Công thức:**

$$L(R,S) = \frac{1}{|R| \cdot |S|} \sum_{i \in R} \sum_{j \in S} D(i,j)$$

- **Giải thích:** Tính trung bình khoảng cách của tất cả các cặp điểm giữa hai cụm.
- **Hệ quả:** Cân bằng giữa single và complete: cụm không quá mảnh, cũng không quá chặt.
- **Ưu điểm:** Kết quả clustering ổn định, ít bị ảnh hưởng mạnh bởi ngoại lệ GeeksforGeeks

4. Ward's Linkage (Phương pháp Ward)

- **Công thức:**

$$L(R,S) = \frac{|R| + |S|}{|R|\,|S|} \sum_{i \in R} \sum_{j \in S} D(i,j)$$

- **Giải thích:** Tập trung vào việc giảm tối đa phương sai bên trong cụm khi gộp hai cụm
- **Hệ quả:** Tạo cụm rất đồng nhất, phân biệt rõ ràng giữa các cụm.
- **Ứng dụng nổi bật:** Được ưa dùng khi cần cấu trúc cụm có chất lượng cao, rõ ràng

5. Centroid Linkage (Liên kết trung tâm cụm)

- **Công thức:**

$$L(R, S) = D(\bar{R}, \bar{S})$$

Trong đó $\bar{R}$, $\bar{S}$ là trung tâm (centroid) của từng cụm.

- **Giải thích:** Khoảng cách giữa hai cụm lấy theo khoảng cách giữa các centroid.
- **Hệ quả:** Thích hợp với cụm hình cầu đồng đều.
- **Hạn chế:** Với cụm có hình dạng bất thường, có thể gây ra cụm "trống" hoặc phân loại sai GeeksforGeeks +3 .

K-Means Clustering là gì?

K-Means là một thuật toán học máy **không giám sát (unsupervised learning)** được sử dụng để **phân nhóm dữ liệu (clustering)** thành **K cụm (clusters)**, sao cho các điểm trong cùng một cụm là **gần nhau nhất có thể** (tương đồng cao) và khác biệt với các cụm khác.

Mục tiêu của K-Means

Tối thiểu hóa tổng bình phương khoảng cách từ mỗi điểm dữ liệu đến **trung tâm cụm (centroid)** của cụm mà nó thuộc về.

🔷 Các bước chính của thuật toán

Bước 1: Chọn số cụm **K**

→ Do người dùng xác định trước (ví dụ: K = 3).

Bước 2: Khởi tạo K trung tâm cụm ban đầu (random)

Bước 3: Gán từng điểm dữ liệu vào cụm gần nhất (dựa trên khoảng cách Euclidean)

$$\text{distance}(x, \mu_k) = \sqrt{\sum_{i=1}^{n} (x_i - \mu_{k_i})^2}$$

Bước 4: Cập nhật lại các **centroid (trung tâm cụm)**

→ Lấy trung bình tất cả các điểm trong cụm đó:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

Bước 5: Lặp lại bước 3–4 cho đến khi:

- Các trung tâm không thay đổi (hội tụ), hoặc
- Số vòng lặp đạt đến giới hạn.

3.2. Thống kê suy luận

3.2.1. Khoảng tin cậy

Trong nghiên cứu và thống kê, việc chọn một **mẫu (sampling)** đại diện từ một **tổng thể (population)** lớn hơn là một phương pháp phổ biến và thiết yếu vì nhiều lý do thực tiễn và khoa học. Thay vì khảo sát toàn bộ dân số, các nhà nghiên cứu thu thập dữ liệu từ một nhóm nhỏ hơn để đưa ra những kết luận về toàn bộ nhóm đó.

Để đảm bảo kết quả từ mẫu có thể suy rộng ra cho toàn bộ tổng thể, mẫu được chọn phải có **tính đại diện**. Điều này có nghĩa là các đặc điểm của mẫu (ví dụ: về độ tuổi, giới tính, thu nhập) phải tương tự như các đặc điểm của tổng thể. Các phương pháp chọn mẫu khoa học, như chọn mẫu ngẫu nhiên, giúp đảm bảo tính đại diện này.

Tiết kiệm chi phí và thời gian

Việc khảo sát toàn bộ một tổng thể, đặc biệt là các tổng thể lớn như dân số một quốc gia, sẽ cực kỳ tốn kém về tiền bạc và đòi hỏi một khoảng thời gian rất dài để thu thập và xử lý dữ liệu. Lấy mẫu giúp giảm đáng kể các chi phí này và cho phép có được kết quả nhanh chóng hơn.

Tính khả thi và thực tiễn

Trong nhiều trường hợp, việc khảo sát toàn bộ tổng thể là không thể thực hiện được. Ngoài ra, một số thử nghiệm có thể làm hỏng hoặc phá hủy sản phẩm (ví dụ: kiểm tra chất lượng bóng đèn), do đó không thể kiểm tra toàn bộ sản phẩm.

Thu thập thông tin chi tiết hơn

Ví dụ. McDonald's, một chuỗi nhà hàng thức ăn nhanh, đã áp dụng quy trình lấy mẫu ngẫu nhiên trong tình huống này. Quy trình lấy mẫu dựa trên thực tế là một số khách hàng đã xuất trình phiếu giảm giá. Bất cứ khi nào một khách hàng xuất trình phiếu giảm giá, khách hàng tiếp theo được phục vụ sẽ được yêu cầu hoàn thành bảng câu hỏi về hồ sơ khách hàng. Vì khách hàng đến xuất trình phiếu giảm giá một cách ngẫu nhiên và độc lập với những khách hàng khác, nên quy trình lấy mẫu này đảm bảo rằng khách hàng được chọn một cách độc lập. Kết quả là, mẫu đáp ứng các yêu cầu của một mẫu ngẫu nhiên từ một quần thể vô hạn.

Các tình huống liên quan đến việc lấy mẫu từ một quần thể vô hạn thường liên quan đến mộtquy trình hoạt động theo thời gian.

Ví dụ bao gồm các bộ phận được sản xuất trên dây chuyền sản xuất, các thử nghiệm thực nghiệm lặp lại trong phòng thí nghiệm, các giao dịch diễn ra tại ngân hàng, các cuộc gọi điện thoại đến trung tâm hỗ trợ kỹ thuật và khách hàng vào cửa hàng bán lẻ.

Trong mỗi trường hợp,tình huống này có thể được xem như một quy trình tạo ra các phần tử từ một quần thể vô hạn.Miễn là các phần tử được lấy mẫu được chọn từ cùng một quần thể và được chọn một cách độc lập, thì mẫu được coi là một mẫu ngẫu nhiên từ một quần thể vô hạn.

Khái niệm Ước lượng khoảng (Interval Estimation)

Trong khi **ước tính điểm** (point estimation) cung cấp một giá trị duy nhất làm phỏng đoán tốt nhất cho tham số tổng thể, nó không cho chúng ta biết ước tính đó gần với giá trị thực của tham số đến mức nào. **Ước lượng khoảng** giải quyết vấn đề này bằng cách cung cấp một khoảng (một phạm vi giá trị) mà có khả năng chứa tham số tổng thể.

Một **ước lượng khoảng** được xây dựng dựa trên ước tính điểm và cộng/trừ đi một giá trị gọi là **biên sai số (margin of error)**.

Ước lượng khoảng có dạng: **Ước tính điểm ± margin error**

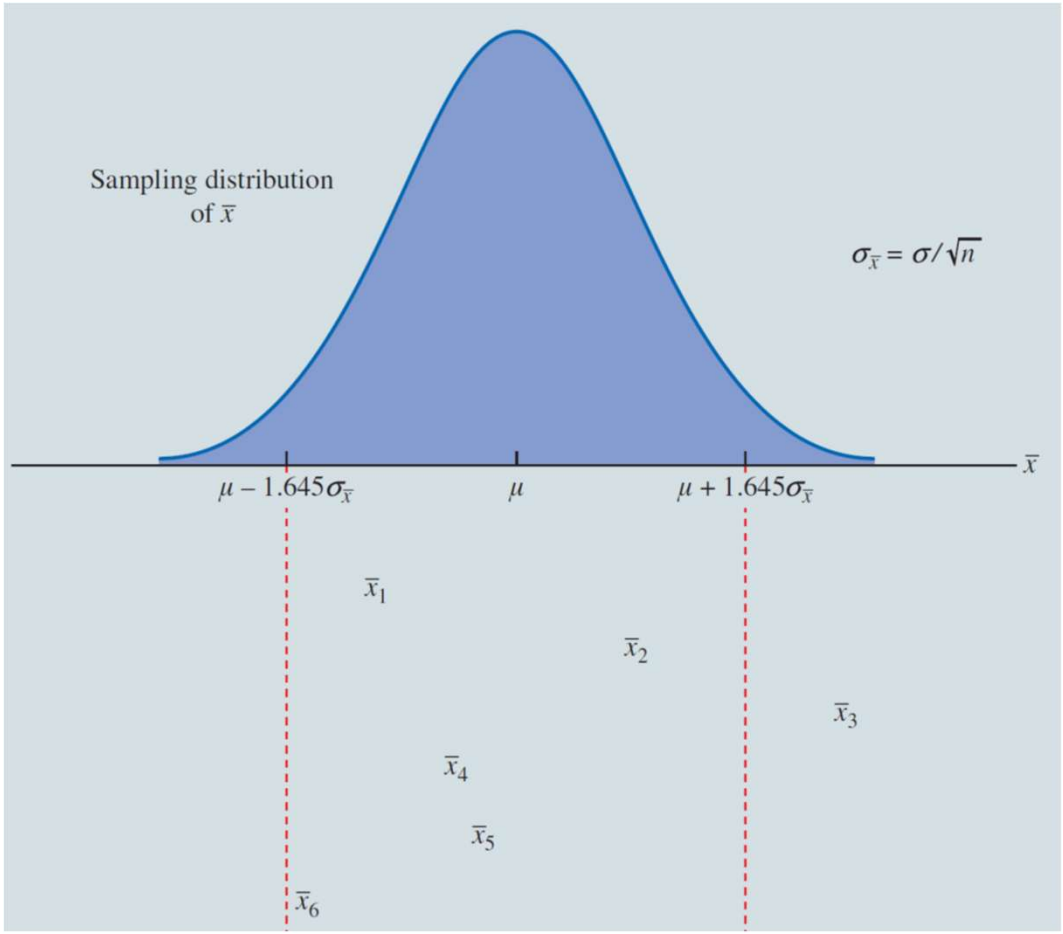
Quá trình xây dựng một ước lượng khoảng cho một tham số tổng thể được gọi là **ước lượng khoảng**. Mục tiêu của ước lượng khoảng là cung cấp thông tin về mức độ gần gũi của ước tính điểm so với tham số tổng thể.

ƯỚC LƯỢNG KHOẢNG CHO TRUNG BÌNH TỔNG THỂ

$$\bar{x} \pm t_{\alpha/2} \cdot \frac{s}{\sqrt{n}},$$

trong đó:

- s là độ lệch chuẩn mẫu,
- α là mức ý nghĩa, và
- $t_{\alpha/2}$ là giá trị tới hạn của phân phối t, ứng với diện tích $\alpha/2$ ở phía trên của phân phối t với số bậc tự do là $n-1$.


Sampling distribution of $\bar{x}$
$\sigma_{\bar{x}} = \sigma/\sqrt{n}$
$\mu - 1.645\sigma_{\bar{x}}$
μ
$\mu + 1.645\sigma_{\bar{x}}$
$\bar{x}$
$\bar{x}_1$
$\bar{x}_2$
$\bar{x}_3$
$\bar{x}_4$
$\bar{x}_5$
$\bar{x}_6$

📘 Ước lượng khoảng tin cậy cho **tỷ lệ tổng thể** (Confidence Interval for a Population Proportion)

Khi bạn lấy mẫu từ một quần thể và muốn ước lượng tỷ lệ (proportion) một đặc điểm nào đó (ví dụ: tỷ lệ người ủng hộ một chính sách, tỷ lệ khách hàng hài lòng,...), bạn có thể dùng công thức sau:

- **Công thức khoảng tin cậy cho tỷ lệ tổng thể:**

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

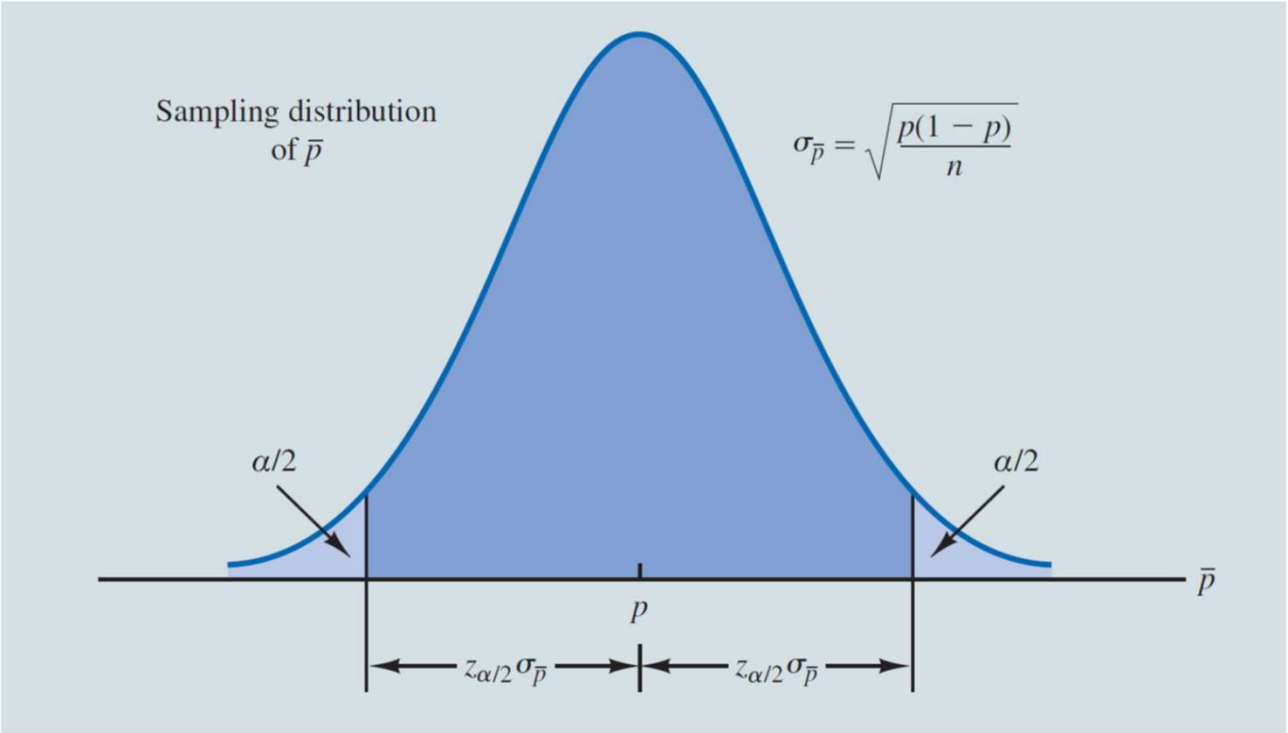
Trong đó:

- $\hat{p}$: Tỷ lệ mẫu (sample proportion), tính bằng $\hat{p} = \frac{x}{n}$, với:
  - x: số đơn vị trong mẫu có đặc điểm cần khảo sát
  - n: kích thước mẫu
- $z_{\alpha/2}$: giá trị tới hạn từ **phân phối chuẩn chuẩn hóa** (Z), ứng với mức ý nghĩa α
- α: Mức ý nghĩa (ví dụ: 0.05 tương ứng với mức tin cậy 95%)
- $\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$: sai số chuẩn (standard error) của tỷ lệ

Điều kiện áp dụng:

Để áp dụng công thức này, cần thoả mãn điều kiện xấp xỉ phân phối chuẩn:

$$n\hat{p} \geq 5 \quad \text{và} \quad n(1-\hat{p}) \geq 5$$


Sampling distribution of $\bar{p}$
$\sigma_{\bar{p}} = \sqrt{\frac{p(1-p)}{n}}$
$\alpha/2$
$\alpha/2$
$\bar{p}$
p
$z_{\alpha/2}\sigma_{\bar{p}}$
$z_{\alpha/2}\sigma_{\bar{p}}$

3.2.2. Kiểm định giả thuyết

Khái niệm về Giả thuyết (Hypothesis)

Trong thống kê, **giả thuyết** là một **phát biểu hoặc khẳng định** về một tham số của tổng thể (population), ví dụ như trung bình, tỷ lệ, phương sai,…

Giả thuyết sẽ được **kiểm định bằng dữ liệu mẫu**, thông qua một quy trình gọi là **kiểm định giả thuyết (hypothesis testing)**.

a. Giả thuyết không (Null Hypothesis – H_0)

- Là phát biểu **mặc định**, đại diện cho trạng thái hiện tại, hoặc "không có sự khác biệt/không có ảnh hưởng".
- Ví dụ:
  - $H_0 : \mu = 50$ (trung bình không thay đổi)
  - $H_0 : p = 0.5$ (tỷ lệ như cũ)

b. Giả thuyết đối (Alternative Hypothesis – H_1 hoặc H_a)

- Là phát biểu **mang tính thay thế** cho H_0, cho rằng có sự thay đổi, khác biệt, ảnh hưởng.
- Ví dụ:
  - $H_1 : \mu \neq 50$
  - $H_1 : p > 0.5$

Loại kiểm định	H_1 (giả thuyết đối)	Mục đích
2 phía	$\mu \neq \mu_0$ hoặc $p \neq p_0$	Kiểm tra sự **khác biệt**
1 phía trái	$\mu < \mu_0$ hoặc $p < p_0$	Kiểm tra **giảm đi**
1 phía phải	$\mu > \mu_0$ hoặc $p > p_0$	Kiểm tra **tăng lên**

Mức ý nghĩa (Significance Level – α)

- Là xác suất **bác bỏ** H_0 khi thực tế H_0 **là đúng** (tức là **xác suất sai lầm loại I**).
- Thường dùng:
  - $\alpha = 0.05$ (mức tin cậy 95%)
  - $\alpha = 0.01$ (tin cậy 99%)
- α càng nhỏ → càng **thận trọng**, ít chấp nhận rủi ro sai.

Các lỗi trong kiểm định giả thuyết

Loại lỗi	Diễn giải
Loại I	Bác bỏ H_0 khi H_0 đúng (xác suất = α)
Loại II	Không bác bỏ H_0 khi H_1 đúng (xác suất = β)

Quy trình kiểm định giả thuyết

1. Xác định H_0 và H_1
2. Chọn mức ý nghĩa α
3. Chọn test phù hợp (Z-test, T-test, v.v.)
4. Tính thống kê kiểm định
5. So sánh với ngưỡng tới hạn hoặc p-value
6. Kết luận: bác bỏ hay không bác bỏ H_0

THANK YOU FOR WATCHING

HỌC VIỆN NGÂN HÀNG
BANKING ACADEMY OF VIETNAM

Học viện Ngân hàng
12 P. Chùa Bộc, P. Quang Trung,
Q. Đống Đa, TP. Hà Nội

T: 1900 561 595 **F:** 1900 561 595
E: truyenthong@hvnh.edu.vn
W: www.hvnh.edu.vn